

**PREDIKSI KURS RUPIAH TERHADAP DOLAR AMERIKA  
SERIKAT BERDASARKAN INFLASI DI INDONESIA DENGAN  
BANTUAN PENDEKATAN MODEL MARKOV TERSEMBUNYI  
YANG DILATIH ALGORITMA BAUM-WELCH**

**TUGAS AKHIR**

**Muhammad Fathir Fadillah  
121450098**

**PROGRAM STUDI SAINS DATA  
FAKULTAS SAINS  
INSTITUT TEKNOLOGI SUMATERA  
LAMPUNG SELATAN  
2024**

**PREDIKSI KURS RUPIAH TERHADAP DOLAR AMERIKA  
SERIKAT BERDASARKAN INFLASI DI INDONESIA DENGAN  
BANTUAN PENDEKATAN MODEL MARKOV TERSEMBUNYI  
YANG DILATIH ALGORITMA BAUM-WELCH**

**TUGAS AKHIR**

**Diajukan sebagai syarat untuk memperoleh gelar sarjana**

**Muhammad Fathir Fadillah  
121450098**

**PROGRAM STUDI SAINS DATA  
FAKULTAS SAINS  
INSTITUT TEKNOLOGI SUMATERA  
LAMPUNG SELATAN  
2024**

## LEMBAR PENGESAHAN

Tugas Akhir dengan judul "Prediksi Kurs Rupiah Terhadap Dolar Amerika Serikat Berdasarkan Inflasi Di Indonesia Dengan Bantuan Pendekatan Model Markov Tersembunyi Yang Dilatih Algoritma Baum-Welch" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan diserahkan sebelumnya, baik sebagian ataupun seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 2025  
Penulis,

Muhammad Fathir Fadillah  
NIM 121450098



Pembimbing I

Pembimbing II

Mika Alvionita S, M.Si  
NIP.1993050920212258

Tirta Setiawan, S.Pd.,M.Si  
NIP.199008222022031003

Disahkan oleh,  
Koordinator Program Studi Sains Data  
Fakultas Sains  
Institut Teknologi Sumatera

Tirta Setiawan, S.Pd.,M.Si  
NIP.199008222022031003

## **HALAMAN PERNYATAAN ORISINALITAS**

**Skripsi ini adalah karya saya sendiri, dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan benar.**

**Nama : Muhammad Fathir Fadillah**

**NIM : 121450098**

**Tanda Tangan :**

**Tanggal : xx xxxx 20xx (Tanggal disetujui)**

## HALAMAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : Muhammad Fathir Fadillah  
NIM : 121450098  
Program Studi : Sains Data  
Fakultas : Sains  
Jenis Karya : Laporan Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Sumatera **Hak Bebas Royalti Noneksklusif** (*Non-exclusive Royalty Free Right*) atas karya ilmiah saya yang berjudul:

### Judul Skripsi Anda

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (database), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta. Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Lampung Selatan  
Pada tanggal : xx xxxx 20xx

Yang menyatakan,

Muhammad Fathir Fadillah

**PREDIKSI KURS RUPIAH TERHADAP DOLAR AMERIKA SERIKAT  
BERDASARKAN INFLASI DI INDONESIA DENGAN BANTUAN  
PENDEKATAN MODEL MARKOV TERSEMBUNYI YANG DILATIH AL-  
GORITMA BAUM-WELCH**

**Muhammad Fathir Fadillah (121450098)**

**Mika Alvionita S, M.Si.**

**Tirta Setiawan, S.Pd., M.Si**

**ABSTRAK**

Nilai tukar terhadap dolar Amerika Serikat menjadi sebuah parameter kemajuan ekonomi suatu negara. Nilai tukar rupiah terhadap dolar Amerika Serikat memiliki pengaruh terhadap inflasi. Kurs rupiah terhadap dolar Amerika Serikat dan inflasi seringkali mengalami fluktuasi sehingga hubungannya terkadang tidak selaras. Nilai kurs yang krusial mendorong untuk adanya prediksi terhadapnya. Salah satu cara memprediksi kurs berdasarkan inflasi, yaitu dengan model stokastik, salah satunya model markov tersembunyi yang dilatih algoritma Baum-Welch. Data bulanan kurs rupiah terhadap dolar Amerika Serikat dan inflasi di Indonesia dari Januari 2019- September 2023 sebagai data latih, dan Oktober 2023 - Agustus 2024 sebagai data uji. Model menghasilkan likelihood sebesar 0.000053 yang meningkat menjadi 0.001651 setelah pelatihan. Model tepat memprediksi 6 dari 11 urutan hidden state berupa kenaikan terus-menerus. Setelah dilatih, model tepat memprediksi 7 dari 11 urutan state tersembunyi dan urutannya lebih fluktuatif. Setelah dilatih dengan algoritma Baum-Welch, prediksi yang dilakukan dengan bantuan model markov tersembunyi menurunkan nilai RMSE, MSE, dan MAPE. RMSE turun dari 948.411 ke 655.177, MSE turun dari 899485.271 ke 429257.466, dan MAPE turun dari 5.13% ke 3.03%. Hal ini menjadikan model markov tersembunyi yang dilatih algoritma Baum-Welch lebih unggul dari segi ketepatan prediksi serta likelihood.

**Kata kunci:** Algoritma Baum-Welch, Model Markov Tersembunyi, Kurs

**PREDIKSI KURS RUPIAH TERHADAP DOLAR AMERIKA SERIKAT  
BERDASARKAN INFLASI DI INDONESIA DENGAN BANTUAN  
PENDEKATA NMODEL MARKOV TERSEMBUNYI YANG DILATIHAL  
GORITMA BAUM-WELCH**

**Muhammad Fathir Fadillah (121450098)**

**Mika Alvionita S, M.Si.**

**Tirta Setiawan, S.Pd., M.Si**

**ABSTRACT**

The exchange rate against the US dollar is a parameter of a country's economic progress. The exchange rate is influenced by several things, one of which is inflation. Both inflation and the exchange rate also experience inflation. The crucial exchange rate encourages predictions about it. One way to predict the exchange rate based on inflation is with the help of the HMM approach trained by the Baum-Welch algorithm. Monthly data on the rupiah exchange rate against the US dollar and inflation in Indonesia from January 2019-September 2023 as training data, and October 2023 - August 2024 as test data. The model produces a *likelihood* of 0.000053 which increases to 0.001922 after training. The model correctly predicts 6 out of 11 *hidden state* sequences, after training the prediction can become more volatile and correctly predict 7 out of 11 *hidden state* sequences. Training the model reduces errors in each *hidden state* change scheme. The increasing-decreasing averaging scheme experienced a decrease in RMSE, MSE, and MAPE from 948.411 to 655.177, 899485.271 to 429257.466, and 5.13% to 3.03%. The transition averaging scheme experienced a decrease in RMSE, MSE, and MAPE from 1277.693 to 616.247, 1632500 to 379761.145, and 6.92% to 2.9%. This makes the HMM trained by the Baum-Welch algorithm superior in terms of prediction accuracy and likelihood.

**Keywords:** *Baum-Welch Algorithm, Hidden Markov Model, Exchange Rate*

## MOTTO

*Ini mottoku, mana motto-mu?.*



## **HALAMAN PERSEMBAHAN**

*Ini persembahkan*

## DAFTAR ISI

<b>LEMBAR PENGESAHAN</b> . . . . .	<b>i</b>
<b>HALAMAN PERNYATAAN ORISINALITAS</b> . . . . .	<b>ii</b>
<b>HALAMAN PERSETUJUAN PUBLIKASI</b> . . . . .	<b>iii</b>
<b>ABSTRAK</b> . . . . .	<b>iv</b>
<b>ABSTRACT</b> . . . . .	<b>v</b>
<b>MOTTO</b> . . . . .	<b>vi</b>
<b>HALAMAN PERSEMBAHAN</b> . . . . .	<b>vii</b>
<b>DAFTAR ISI</b> . . . . .	<b>viii</b>
<b>DAFTAR GAMBAR</b> . . . . .	<b>x</b>
<b>DAFTAR TABEL</b> . . . . .	<b>xi</b>
<b>DAFTAR SIMBOL</b> . . . . .	<b>xiii</b>
<b>I Pendahuluan</b> . . . . .	<b>1</b>
1.1 Latar Belakang . . . . .	1
1.2 Rumusan Masalah . . . . .	3
1.3 Tujuan . . . . .	3
1.4 Batasan Masalah . . . . .	3
<b>II Tinjauan Pustaka</b> . . . . .	<b>4</b>
2.1 <i>State of The Art</i> . . . . .	4
2.2 Kurs Dolar dan Inflasi . . . . .	5
2.3 Probabilitas . . . . .	5
2.3.1 Definisi Probabilitas . . . . .	5
2.3.2 Probabilitas Bersyarat . . . . .	6
2.3.3 Probabilitas Bayes . . . . .	6
2.4 Proses Markov . . . . .	6
2.5 Model Markov Tersmbunyi . . . . .	7
2.5.1 Definisi . . . . .	7
2.5.2 Parameter dan Sifat . . . . .	8
2.5.3 Peran Probabilitas Bayes pada <i>Hidden Markov Model</i> . . . . .	9
2.5.4 <i>Likelihood Hidden Markov Model</i> (HMM) . . . . .	11
2.5.5 <i>Arsitektur Hidden Markov Model</i> . . . . .	11
2.6 Ketidaksamaan Jensen . . . . .	11
2.7 Pengali Lagrange . . . . .	12
2.8 Algoritma Viterbi . . . . .	12
2.9 Algoritma Baum-Welch . . . . .	13
2.9.1 Definisi dan Hubungan dengan <i>Expectation Maximization</i> (EM) . . . . .	13
2.9.2 Algoritma <i>Forward</i> dan <i>Backward</i> . . . . .	16
2.10 Evaluasi Model . . . . .	19
<b>III Metode Penelitian</b> . . . . .	<b>21</b>
3.1 Deskripsi Data . . . . .	21

3.2 Tahapan Penelitian . . . . .	21
<b>IV Hasil dan Pembahasan . . . . .</b>	<b>23</b>
4.1 Parameter dan <i>Likelihood</i> Model Sesudah Serta Sebelum Pelatihan Oleh Algoritma Baum-Weclch . . . . .	24
4.1.1 Parameter Model Sebelum Pelatihan . . . . .	25
4.1.2 Parameter dan <i>Likelihood</i> Model Setelah Pelatihan . . . . .	28
4.2 Prediksi Urutan Kondisi Kurs Rupiah Terhadap Dolar Amerika Serikat . . . . .	48
4.3 Prediksi Kurs Rupiah . . . . .	53
<b>V Kesimpulan dan Saran . . . . .</b>	<b>56</b>
5.1 Kesimpulan . . . . .	56
5.2 Saran . . . . .	56
<b>DAFTAR PUSTAKA . . . . .</b>	<b>58</b>
<b>LAMPIRAN . . . . .</b>	<b>62</b>
<b>LAMPIRAN . . . . .</b>	<b>62</b>
<b>A Perhitungan Manual . . . . .</b>	<b>63</b>
A.1 Parameter Awal . . . . .	63
A.2 Urutan Observasi . . . . .	63
A.3 Algoritma Viterbi . . . . .	63
A.3.1 Perhitungan $\delta_t(i)$ . . . . .	63
A.3.2 Tabel $\delta_t(i)$ . . . . .	64
A.3.3 Perhitungan $\psi_t(i)$ . . . . .	64
A.3.4 Tabel $\psi_t(i)$ . . . . .	64
A.4 Perhitungan $\alpha$ dan $\beta$ . . . . .	65
A.4.1 Perhitungan $\alpha_t(i)$ . . . . .	65
A.4.2 Tabel $\alpha_t(i)$ . . . . .	65
A.4.3 Likelihood Model . . . . .	65
A.5 Perhitungan $\beta$ . . . . .	65
A.5.1 Inisialisasi $\beta_{11}(i)$ . . . . .	65
A.5.2 Perhitungan $\beta_{10}(i)$ . . . . .	66
A.5.3 Tabel $\beta_t(i)$ . . . . .	66
A.6 Perhitungan $\xi$ dan $\gamma$ . . . . .	66
A.6.1 Rumus $\xi_t(i,j)$ . . . . .	66
A.6.2 Contoh Perhitungan $\xi_1(i,j)$ . . . . .	66
A.6.3 Tabel $\xi_t(i,j)$ . . . . .	67
A.6.4 Rumus $\gamma_t(i)$ . . . . .	67
A.6.5 Tabel $\gamma_t(i)$ . . . . .	67
A.7 Pembaruan Parameter . . . . .	68
A.7.1 Matriks Transisi $A^*$ . . . . .	68
A.7.2 Matriks Emisi $B^*$ . . . . .	68
A.7.3 Vektor Probabilitas Awal $\pi^*$ . . . . .	68
A.8 Parameter Hasil Pelatihan . . . . .	68
A.9 Prediksi dan Evaluasi . . . . .	68
A.9.1 Urutan State Tersembunyi . . . . .	68

A.9.2	Konversi ke Nilai Kontinu . . . . .	69
A.9.3	Evaluasi Prediksi . . . . .	69

## DAFTAR GAMBAR

Gambar 2.1	Arsitektur <i>Hidden Markov Model</i> . . . . .	11
Gambar 3.1	diagram Alir Penelitian. . . . .	21
Gambar 4.1	Plot Data Kurs Dolar Amerika Serikat Terhadap Rupiah. . .	23
Gambar 4.2	Plot Data Inflasi Di Indonesia. . . . .	24
Gambar 4.3	Plot Prediksi Berdasarkan Skema Penurunan-Kenaikan . . .	54

## DAFTAR TABEL

Tabel 2.1	<i>State of the art</i> . . . . .	4
Tabel 2.2	Range Nilai MAPE. . . . .	20
Tabel 4.1	Tabel Kurs dan Inflasi . . . . .	24
Tabel 4.2	Transisi antara bulan ke- $n$ dan bulan ke- $n + 1$ . . . . .	25
Tabel 4.3	Hubungan antara kurs dan inflasi . . . . .	27
Tabel 4.4	Jumlah Bulan berdasarkan Kondisi Kurs . . . . .	28
Tabel 4.5	Tabel Nilai $\alpha$ dan $\beta$ yang digunakan Sepanjang Iterasi Pelatihan . . . . .	31
Tabel 4.6	Tabel Hasil $\xi_n(i,j)$ , dan $\gamma_n(i)$ Tiap Iterasi Pelatihan . . . . .	36
Tabel 4.7	Hasil Pembaruan Parameter Model Sepanjang Iterasi Pelatihan . . . . .	46
Tabel 4.8	Nilai $\delta$ Sebelum Pelatihan . . . . .	49
Tabel 4.9	Nilai $\psi$ Sebelum Pelatihan . . . . .	49
Tabel 4.10	Nilai $\delta$ Sesudah Menyelesaikan Pelatihan . . . . .	50
Tabel 4.11	Nilai $\psi$ Sesudah Menyelesaikan Pelatihan . . . . .	51
Tabel 4.12	Tabel Prediksi dan Observasi dengan Bantuan Baum-Welch	52
Tabel 4.13	Tabel Data Kurs dengan Prediksi . . . . .	55

## DAFTAR SIMBOL

### DAFTAR SIMBOL

$N$	: Panjang observasi yang dilakukan
$X$	: Himpunan urutan state observasi
$X_n$	: State observasi yang terjadi pada waktu ke- $n$
$Z$	: Himpunan urutan hidden state
$Z_n$	: Hidden state yang terjadi pada waktu ke- $n$
$\delta_n(j)$	: Nilai maksimum probabilitas waktu ke- $n$ adalah melalui $j$
$\psi_n(j)$	: Hidden state sebelumnya yang paling memaksimumkan probabilitas waktu ke- $n$ adalah $j$
$P^*$	: Nilai maksimum probabilitas untuk setiap $\delta_N(j)$
$Q^*$	: Hidden state yang memaksimumkan $\delta_N(j)$
$q_n$	: Hidden state yang diprediksi terjadi pada waktu ke- $n$
$\alpha$	: Koefisien forward
$\beta$	: Koefisien backward
$\theta$	: Himpunan parameter Hidden Markov Model (HMM)
$B_{iq}$	: Probabilitas emisi saat waktu ke- $n$ hidden state adalah $i$ dan state observasi adalah $q$
$A_{ij}$	: Probabilitas transisi hidden state dari $i$ ke $j$
$\pi_i$	: Probabilitas inisiasi hidden state $i$
$M$	: Himpunan state observasi yang mungkin terjadi
$S$	: Himpunan hidden state yang mungkin terjadi
$L_{iq}$	: Banyak kejadian hidden state $i$ bersamaan dengan state observasi $q$
$K_{ij}$	: Banyak kejadian transisi hidden state dari $i$ ke $j$
$F_i$	: Frekuensi terjadinya hidden state $i$
$y_n$	: Nilai aktual kurs dolar Amerika Serikat waktu ke- $n$
$\hat{y}_n$	: Nilai estimasi kurs dolar Amerika Serikat waktu ke- $n$

# BAB I

## Pendahuluan

### 1.1 Latar Belakang

Sebuah negara keadaan ekonominya dikatakan stabil serta baik jika pergerakan nilai tukar mata uangnya stabil [1]. Stabil yang dimaksud di sini adalah fluktuasinya yang cenderung relatif kecil. Nilai tukar mata uang atau kurs sangat diperlukan dalam menjalankan transaksi internasional [2]. Saat ini dunia menggunakan dolar Amerika Serikat sebagai mata uang dalam perihal transaksi [3]. Dolar Amerika Serikat dipandang sebagai mata uang yang cukup krusial secara internasional karena kedudukannya sebagai *hard currency*. Istilah ini merujuk pada mata uang yang relatif stabil, kuat, dan meningkat terhadap mata uang lain [4]. Tentunya Indonesia perlu memerhatikan kurs rupiah dolar Amerika Serikat. Kurs rupiah terhadap dolar Amerika Serikat merupakan tolak ukur perkembangan dan kemajuan ekonomi Indonesia [5]. Selain sebagai salah satu tolak ukur kemajuan ekonomi Indonesia di ranah internasional, kurs rupiah terhadap dolar Amerika Serikat juga memiliki pengaruh terhadap inflasi di Indonesia. Inflasi yakni fenomena suatu harga secara umum yang meningkat kontinu [6]. Inflasi rendah dan stabil dapat meningkatkan pertumbuhan ekonomi, sedangkan inflasi tidak stabil atau terlampaui tinggi mengakibatkan pertumbuhan ekonomi suatu negara menjadi buruk [7]. Inflasi dijadikan patokan yang krusial dalam pengkajian tingkat ekonomi suatu negara [8]. Lonjakan inflasi diakibatkan oleh kurs Rupiah terhadap dolar Amerika Serikat [9]. Melemahnya kurs akan menaikkan harga barang asing, hal ini dikarenakan barang tersebut memerlukan biaya yang lebih, hal ini juga terjadi pada barang yang diproduksi dari bahan impor [10]. Begitu juga sebaliknya, saat terjadi apresiasi kurs rupiah terhadap dolar Amerika Serikat, biaya impor lebih murah [11]. Penurunan biaya impor menjadikan harga barang asing menurun.

Kurs rupiah terhadap dolar Amerika Serikat dan juga inflasi keduanya mengalami fluktuasi yang beragam dan tidak jarang membuatnya tidak selaras. Banyak hal yang mengakibatkan terjadinya fenomena ini, terutama peristiwa-peristiwa yang memiliki dampak global. Pada permulaan tahun 2020 hampir seluruh dunia termasuk Indonesia ditimpa pandemi *Coronavirus Disease 2019* (COVID-19) menjadikan melemahnya kurs rupiah terhadap mata uang asing [12]. Di masa itu, ekonomi dunia mengalami penurunan dikarenakan adanya pembatasan terhadap mobilisasi, penutupan bisnis, pengangguran, dan juga gangguan yang dialami rantai pasok [13]. Namun, di masa tersebut sempat terjadi penurunan inflasi terutama pertengahan 2020 sampai pertengahan 2021. Hal ini dikarenakan oleh beberapa hal, misalnya apresiasi angka pengangguran. Fenomena apresiasi banyaknya pengangguran yang bertolak belakang dengan inflasi dinamakan kurva Phillips [14]. Dalam jangka pendek yang dipengaruhi ekspektasi fluktuasi terhadap inflasi, kurva Phillips menegaskan bila terjadi peningkatan angka pengangguran maka inflasi akan turun dan begitu juga



sebaliknya [15]. Selain *Coronavirus Disease 2019* (COVID-19) ada juga faktor lain seperti konflik internasional. Konflik Ukraina-Rusia yang dimulai pada Februari 2022 hingga saat ini adalah salah satu contohnya. Krisis geopolitik mengenai perang Ukraina-Rusia memberikan dampak berupa lonjakan harga energi dunia yang berefek pada melemahnya kurs rupiah serta terjadinya inflasi [16]. Meskipun secara teoritis mereka dapat berfluktuasi diakibatkan banyak hal, akan tetapi terdapat perbedaan terutama dari segi intervensi pihak yang berwenang terhadap mereka. Indonesia menerapkan sistem kurs mengambang bebas. Sistem kurs mengambang bebas sepenuhnya bergantung pada pasar demi mencapai kesetimbangan eksternal maupun internal, artinya tidak ada intervensi pemerintah terhadapnya [17]. Sistem kurs mengambang ditambah devisa bebas sejak tahun 1997 menjadikan kurs menjadi dipengaruhi banyak faktor baik ekonomi maupun non-ekonomi [18]. Berbeda halnya dengan inflasi, intervensi pemerintah terhadap inflasi relatif lebih kuat dibandingkan terhadap kurs. Pemerintah dan juga Bank Indonesia (BI) mendedikasikan kebijakan demi tercapainya target inflasi yang telah diputuskan lewat harmonisasi yang selaras dengan target tersebut [19]. Perbedaan besarnya intervensi pemerintah dan/atau lembaga resmi terhadap kurs dan inflasi menjadikan keduanya relatif memiliki tingkat kesukaran penentuan. Kurs relatif lebih sukar ditentukan dibandingkan inflasi yang dipenuhi oleh campur tangan pemerintah dan/atau lembaga resmi.

Prediksi kurs rupiah terhadap dolar Amerika Serikat menjadi hal yang krusial mengingat dolar Amerika Serikat sebagai *hard currency*. Prediksi nilai tukar Rupiah ke Dolar Amerika Serikat sebelumnya telah dilakukan oleh G.P. Brian Are dan Sampe Hotlan Sitorus(2020) dengan menggunakan data kurs harga jual Dolar Amerika Serikat terhadap Rupiah pada tahun 2018 untuk prediksi tren pada tahun 2019 yang menggunakan pemodelan Hidden Markov Model (HMM), untuk rentang periode 1 bulan, 3 bulan, dan 1 tahun menghasilkan nilai Mean Absolute Deviation (MAD), Mean Squared Error (MSE), dan Mean Absolute Percentage Error(MAPE) masing-masing sebesar (0,27; 0,27; dan 0.45), (0,81;0,81; dan 2.27), dan (2,48%; 2,48%; dan 4,14%) [20]. Penelitian lainnya juga telah dilakukan oleh Mahmudi dan Ardi (2016) dengan menggunakan data harian kurs jual dan beli dolar Amerika Serikat terhadap dimulai dari tanggal 23 Juni 2014 sampai 31 Juli 2015 sebanyak 273 observasi menghasilkan pengelompokan state kurs beli menjadi rentang interval [-180 ; -45.09], [-45.08 ; 0], [0.001 ; 40.42], dan [40.43 ; 299] dengan barisan observasi optimalnya  $X = S1, S2, S3$ , sedangkan untuk pengelompokan state kurs jual menjadi rentang interval [-182 ; -45.56], [-45,55 ; 0], [0.001 ; 40.83], dan [40,84 ; 303] dengan barisan observasi optimalnya  $X = S2, S3, S2$  [21].

Pengembangan penelitian dalam konteks prediksi kurs Rupiah terhadap Dolar Amerika Serikat diperlukan. Melakukan prediksi kurs Rupiah terhadap Dolar Amerika Serikat berdasarkan inflasi salah satu contohnya, mengingat dalam praktiknya keduanya saling berhubungan. Namun, tidak jarang ditemukan hubungan kurs rupiah dengan dolar Amerika Serikat tidak linear dan juga saling berfluktuasi. Pola fluktuasi dan penyebabnya yang acak menjadikan proses stokastik mampu berkontribusi dalam upaya prediksi kurs. Proses stokastik yakni

sebuah cabang dari ilmu yang mengkaji kejadian yang mengandung unsur acak [22]. Unsur acak di sini merujuk ke pola fluktuasi kurs dan inflasi. Salah satu pemodelan stokastik yang dapat digunakan ialah *Hidden Markov Model* (HMM) yang merupakan perluasan dari rantai markov. Melalui model ini, kurs yang relatif lebih sukar ditentukan dibandingkan dengan inflasi (mengandung efek dari kurs itu) karena kurangnya intervensi, dijadikan sebagai *hidden state*. Sebaliknya, inflasi akan dijadikan sebagai *state* observasi.

Berfokus pada model yang dibangun, *Hidden Markov Model* tidak jarang menghasilkan performa yang tidak terlalu prima (terutama waktu yang panjang) akibat sifat markov bawaannya. Namun, algoritma Baum-Welch memberikan opsi sebagai bentuk upaya peningkatan performa yang dihasilkan model. Penelitian ini menilai seberapa layak dan cocoknya suatu *Hidden Markov Model* bekerja, serta membandingkannya dengan *Hidden Markov Model* lain yang di mana adalah buah dari upaya peningkatan performa model sebelumnya.

## 1.2 Rumusan Masalah

1. Bagaimana peran kedua (dengan dan tanpa optimasi Baum-Welch) model *Hidden Markov Model* (HMM) memberikan pendekatan yang dijadikan orientasi untuk kepentingan prediksi, untuk nantinya akan saling disandingkan dengan nilai aktual kurs rupiah terhadap dolar Amerika Serikat?
2. Bagaimana kecocokan penggunaan kedua (dengan dan tanpa optimasi Baum-Welch) model *Hidden Markov Model* (HMM) berdasar *likelihood*?

## 1.3 Tujuan

1. Memperoleh estimasi urutan *state* tersembunyi sepanjang observasi beserta peranannya sebagai pendekatan prediksi kurs rupiah terhadap dolar Amerika Serikat untuk dijadikan komparasi performa kerja kedua model (dengan dan tanpa optimasi Baum-Welch).
2. Membandingkan tingkat kecocokan penggunaan kedua model (dengan dan tanpa optimasi Baum-Welch) berdasarkan besarnya *likelihood* yang dihasilkan untuk diambil inferensinya saat menghadapi suatu urutan kondisi inflasi.

## 1.4 Batasan Masalah

Penelitian ini membatasi skema perubahan urutan *state* tersembunyi ke nilai kontinu dengan hanya berdasarkan nilai rerata kenaikan-penurunan *state* tersembunyi. Selain itu, penelitian ini juga membatasi banyaknya *state* tersembunyi dan *state* observasi serta jenis rantai markov yang digunakan. Banyaknya *state* tersembunyi dan *state* observasi adalah 2 dengan rantai markov diskrit.

## BAB II

### Tinjauan Pustaka

#### 2.1 *State of The Art*

Konteks *state of the art* mengacu pada perkembangan, kemajuan, atau pengetahuan terbaru dalam suatu keilmuan atau ranah khusus [23]. Konsep *state of the art* pada penelitian ini ditujukan sebagai upaya pembentukan pembaharuan pada penelitian sebelumnya. Penelitian ini melakukan prediksi kurs Rupiah terhadap Dolar Amerika Serikat berdasarkan inflasi di Indonesia Hidden Markov Model (HMM) yang dilatih dengan menggunakan algoritma Baum-Welch. Terdapat beberapa penelitian sebelumnya yang telah dilakukan untuk memprediksi kurs Rupiah terhadap Dolar Amerika Serikat. Penelitian-penelitian tersebut disajikan pada Tabel berikut.

**Tabel 2.1** *State of the art*

Judul Penelitian	Peneliti, Tahun	Data, Metode	Hasil Penelitian
Prediksi Nilai Tukar Mata Uang Rupiah Terhadap Dolar Amerika Menggunakan Metode Hidden Markov Model	G.P. Brian Are, Sampe Hotlan Sitorus, 2020 [20]	Kurs harga jual Dolar Amerika Serikat terhadap Rupiah pada tahun 2018, <i>Hidden Markov Model</i> (HMM)	Rentang periode 1 bulan, 3 bulan, dan 1 tahun menghasilkan nilai MAD, MSE, MAPE masing-masing sebesar (0,27; 0,27; 0,45), (0,81; 0,81; 2,27), dan (2,48%; 2,48%; 4,14%).
Prediksi Kurs Rupiah Terhadap Dolar Dengan <i>FTS-Markov Chain</i> Dan <i>Hidden Markov Model</i>	Maria Titah Jatipaningrum, Kris Suryowati, Libertania Maria Melania Esti Un 2019 [24]	Kurs jual dan beli Dolar Amerika Serikat, <i>FTS-Markov Chain</i> dan <i>Hidden Markov Model</i> (HMM)	Pada periode 1 Desember 2018 menggunakan <i>FTS-MC</i> menghasilkan MAPE atas kurs jual sebesar 1,317% serta MAPE atas kurs beli sebesar 1,355%.

Judul Penelitian	Peneliti, Tahun	Data, Metode	Hasil Penelitian
Prediksi Pergerakan Nilai Tukar Rupiah Terhadap Dolar Amerika Serikat Menggunakan Hidden Markov Model	Mahmudi, Ardi, 2016 [21]	Data harian kurs jual dan beli dolar Amerika Serikat terhadap dimulai dari tanggal 23 Juni 2014 sampai 31 Juli 2015 sebanyak 273 observasi, <i>Hidden Markov Model</i> (HMM)	Pengelompokan state kurs beli dalam interval $[-180; -45,09]$ , $[-45,08; 0]$ , $[0,001; 40,42]$ , dan $[40,43; 299]$ dengan observasi optimal $X = S1, S2, S3$ , state kurs jual dalam interval $[-182; -45,56]$ , $[-45,55; 0]$ , $[0,001; 40,83]$ , dan $[40,84; 303]$ dengan observasi optimal $X = S2, S3, S2$ .

## 2.2 Kurs Dolar dan Inflasi

Kurs umumnya dimaknai sebagai harga mata uang asing pada mata uang domestik dengan menggunakan notulensi yang ditetapkan dalam perniagaan dunia [25]. Kurs dibagi menjadi tiga yakni kurs jual, beli, dan tengah. Kurs jual digunakan bank saat menjual mata uang asing, sedangkan kurs beli digunakan bank saat membeli mata uang asing [20]. Kurs tengah dimaknai sebagai kurs yang nilainya berada di antara kur beli dan jual. Nilainya diperoleh dari menjumlahkan kurs beli dan jual kemudian dibagi dua [26]. Inflasi berasal dari Bahasa latin “*inflance*” yang mempunyai arti “meningkat” [27]. Meningkat di sini merujuk pada harga barang dan/atau jasa secara umum. Peningkatan ini juga menggambarkan melemahnya nilai tukar suatu mata uang baik dengan barang, jasa, maupun mata uang negara lain.

## 2.3 Probabilitas

### 2.3.1 Definisi Probabilitas

Teori Probabilitas yakni besaran yang dipakai untuk mengetahui terjadi atau tidaknya suatu peristiwa [28]. Kejadian A probabilitasnya dinotasikan dengan  $P(A)$  dan memenuhi pertidaksamaan  $[0P(A)1]$  sebagai selang intervalnya. Semakin tinggi nilai  $P(A)$  maka semakin tinggi kemungkinan terjadinya kejadian A. Artinya, nilai suatu kejadian A mustahil terjadi jika nilai  $P(A)=0$  dan pasti terjadi jika  $P(A)=1$ .

### 2.3.2 Probabilitas Bersyarat

Probabilitas bersyarat disimbolkan dengan  $P(B \cap A)$  yang artinya probabilitas terjadinya kejadian B jika diketahui kejadian A sudah terjadi dahulu [29]. Probabilitas bersyarat  $P(B \cap A)$  bergantung dengan probabilitas  $P(B \cap A)$  dan  $P(A)$ . Hubungan ketiganya dapat dituliskan dengan Persamaan 2.1.

$$P(B \cap A) = P(B | A)P(A) \quad (2.1)$$

Untuk mendapatkan  $P(B|A)$  kedua ruas Persamaan 2.1 dibagi dengan  $P(A)$  sehingga dituliskan menjadi Persamaan 2.2.

$$\frac{P(B \cap A)}{P(A)} = P(B | A) \quad (2.2)$$

### 2.3.3 Probabilitas Bayes

Probabilitas bayes yakni suatu cara untuk menangani ketidakpastian data dengan menggunakan formula bayes yang dikenal sebagai dasar dari peluang bersyarat yang *dependent* [30]. Nilai BA sama dengan AB sehingga dapat dituliskan beserta probabilitasnya menjadi Persamaan 2.3 dan 2.4.

$$B \cap A = A \cap B \quad (2.3)$$

$$P(B \cap A) = P(A \cap B) \quad (2.4)$$

Dengan substitusi Persamaan 2.1 ke Persamaan 2.4 diperoleh Persamaan 2.5 [31].

$$P(B | A)P(A) = P(A | B)P(B) \quad (2.5)$$

Nilai  $P(B)$  akan membagi kedua ruas Persamaan 2.5 sehingga didapatkan  $P(B|A)$  sebagai probabilitas posterior yang memenuhi probabilitas bayes pada Persamaan 2.6.

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}, \quad P(B) > 0 \quad (2.6)$$

Untuk  $P(B|A)$  dan  $P(A)$  masing-masing disebut sebagai *likelihood* dan prior.

## 2.4 Proses Markov

Proses markov adalah sebuah proses stokastik yang bersifat apabila keadaan saat ini diketahui, probabilitas keadaan satu langkah ke depannya hanya bergantung pada keadaan proses saat ini [32]. Salah satu proses markov adalah rantai markov diskrit. Rantai markov diskrit yakni sebuah proses markov dengan banyak state terhingga

dalam himpunan waktu  $T = (0,1,2,\dots)$ . Properti markov dapat dituliskan menjadi Persamaan 2.7 [33].

$$P(X_{n+1} = j \mid X_0, \dots, X_{n-1} = i_{n-1}, X_n = i_n) = P(X_{n+1} = j \mid X_n = i) \quad (2.7)$$

Persamaan 2.7 berlaku untuk semua  $n$  dan seluruh state. Probabilitas dari  $X_{n+1}$  pada state  $j$  bersyarat  $X_n$  pada state  $i$  disebut sebagai transisi selangkah serta dinotasikan Persamaan 2.8 [33].

$$P_{ij}^{(n,n+1)} = P(X_{n+1} = j \mid X_n = i) \quad (2.8)$$

Nilai  $P_{ij}^{(n,n+1)}$  bukan hanya terkhusus pada waktu tertentu saja, melainkan juga dari waktu transisi. Nilai  $P_{ij}^{(n,n+1)}$  dapat disimpan dalam bentuk matriks probabilitas transisi. Matriks probabilitas transisi dapat dibangun mengikuti Persamaan 2.9.

$$P_{ij} = \frac{K_{ij}}{\sum_{j \in S} K_{ij}}; \sum_{j \in S} K_{ij} > 0 \quad (2.9)$$

Persamaan 2.9 memberikan cara untuk mendapatkan nilai  $P_{ij}$  dengan menghitung banyak kejadian pada waktu  $n + 1$  adalah state  $j$  bersyarat kejadian waktu  $t$  adalah  $i$  dibagi dengan banyak kejadian pada waktu  $t$  adalah  $i$ . Dengan demikian, nilai  $P_{ij}$  memenuhi Persamaan 2.10 dan 2.11 dengan  $S$  adalah himpunan state.

$$P_{ij} \geq 0, \quad i, j \in S \quad (2.10)$$

$$\sum_{j \in S} P_{ij} = 1 \quad (2.11)$$

Probabilitas setiap kombinasi perpindahan state dapat ditulis dalam bentuk matriks probabilitas transisi  $P$  berdimensi  $S \times S$  dengan  $S$  adalah banyaknya state.

$$P = \begin{bmatrix} P_{11} & \cdots & P_{1S} \\ \vdots & \ddots & \vdots \\ P_{S1} & \cdots & P_{SS} \end{bmatrix} \quad (2.1)$$

## 2.5 Model Markov Tersmbunyi

### 2.5.1 Definisi

Hidden Markov Model adalah suatu proses stokastik ganda yang salah satu prosesnya tidak dapat diamati (tersembunyi) [34]. Rantai Markov yang merepresentasikan perpindahan antar state tidak teramati secara langsung sehingga disebut “tersembunyi” (tersembunyi) dan ini menjadi proses stokastik pertama dalam *Hidden Markov Model*, sedangkan yang kedua adalah probabilitas emisi

yang mampu teramati setiap observasi bergantung *state* tersembunyi [35]. Tersembunyi di sini juga termasuk sesuatu yang lebih sukar diamati ketimbang observasi. *Hidden Markov Model* dikenal juga sebagai automasi stokastik terbatas yang mana sekarang dikenal juga sebagai bentuk spesifik jaringan bayes [35]. Kemampuan penyelesaian masalah evaluasi, kesimpulan, dan pembelajaran dapat diselesaikan oleh *Hidden Markov Model* dengan algoritma *forward* dan *backward*, Viterbi, serta Baum-Welch [36].

### 2.5.2 Parameter dan Sifat

Model ini memiliki tiga parameter yakni probabilitas transisi, emisi, dan inisiasi. Probabilitas transisi pada *Hidden Markov Model* mengacu pada transisi antar *state* tersembunyi serta dapat dituliskan sebagai rantai Markov ukuran  $S \times S$  dengan  $S$  adalah banyak hidden state. Probabilitas transisi dapat dirumuskan dengan Persamaan 2.12 dan direpresentasikan dalam matriks  $A$ .

$$P(Z_n = j \mid Z_{n-1} = i) = A_{ij} \quad (2.12)$$

$$A = \begin{bmatrix} A_{11} & \cdots & A_{1S} \\ \vdots & \ddots & \vdots \\ A_{S1} & \cdots & A_{SS} \end{bmatrix} \quad (2.2)$$

Probabilitas emisi yakni probabilitas state observasi bersyarat *state* tersembunyi dalam waktu yang sama dan dituliskan menjadi 2.13.

$$P(X_n = q \mid Z_n = i) = B_{iq} \quad (2.13)$$

Probabilitas emisi  $B_{ij}$  dapat dihitung dengan Persamaan 2.14.

$$B_{iq} = \frac{L_{iq}}{\sum_{q \in M} L_{iq}} \quad ; \quad \sum_{q \in M} L_{iq} > 0 \quad (2.14)$$

Persamaan 2.14 memberikan cara mendapatkan nilai  $B_{iq}$  dengan menghitung banyak state observasi adalah  $q$  diketahui *hidden state* adalah  $i$  pada waktu  $t$  dibagi dengan banyaknya *hidden state* pada waktu ke  $t$  adalah  $i$ . Dengan demikian, nilai  $B_{iq}$  memenuhi Persamaan 2.15 dan 2.16 dengan  $M$  adalah himpunan *state* observasi.

$$B_{iq} \geq 0 \quad ; \quad i \in S, q \in M \quad (2.15)$$

$$\sum_{q \in M} B_{iq} = 1 \quad (2.16)$$

Probabilitas setiap kombinasi setiap *state* tersembunyi dengan setiap *state* observasi dapat ditulis dalam matriks probabilitas emisi  $B$  berdimensi  $S \times M$  dengan  $M$  adalah banyaknya state observasi.

$$B = \begin{bmatrix} B_{11} & \cdots & B_{1M} \\ \vdots & \ddots & \vdots \\ B_{S1} & \cdots & B_{SM} \end{bmatrix}$$

Parameter yang terakhir adalah probabilitas inisiasi. Probabilitas inisiasi merujuk pada probabilitas awal setiap *state* tersembunyi. Untuk menghitung probabilitas inisiasi setiap *state* tersembunyi menggunakan Persamaan 2.17 yang memenuhi Persamaan 2.18.

$$\pi_i = \frac{F_i}{\sum_{i=1}^S F_i}; \quad 1 \leq i \leq S \quad (2.17)$$

$$\sum_{i=1}^S \pi_i = 1 \quad (2.18)$$

Nilai probabilitas inisiasi untuk setiap *state* tersembunyi dapat dituliskan dalam bentuk vektor probabilitas transisi berukuran  $1 \times S$ .

$$\pi = [\pi_1, \dots, \pi_S]$$

Dari segi teoritis, tidak ada limitasi terhadap kelas distribusi probabilitas yang diwakili *Hidden Markov Model* [37]. Salah satu sifat terkuatnya yakni kemampuannya menunjukkan konsistensi saat terjadinya kompresi atau peregang *state* tersembunyi pada sumbu waktu [38].

### 2.5.3 Peran Probabilitas Bayes pada *Hidden Markov Model*

Probabilitas Bayes dijadikan dasar untuk mengestimasi probabilitas himpunan urutan *state* tersembunyi  $Z = \{Z_1, \dots, Z_N\}$  bersyarat himpunan urutan *state* observasi  $X = \{X_1, \dots, X_N\}$  dengan  $N$  adalah panjang pengamatan. Estimasi himpunan urutan *state* tersembunyi  $Z = \{Z_1, \dots, Z_N\}$  dicari melalui maksimasi nilai probabilitas urutan *state* tersembunyi  $Z = \{Z_1, \dots, Z_N\}$  bersyarat himpunan urutan *state* observasi  $X = \{X_1, \dots, X_N\}$ . Penerapan probabilitas Bayes pada *Hidden Markov Model* (HMM) dirumuskan oleh Persamaan 2.19.

$$P(Z = \{Z_1, \dots, Z_N\} | X = \{X_1, \dots, X_N\}) = \frac{P(X=\{X_1, \dots, X_N\} | Z=\{Z_1, \dots, Z_N\}) p(Z=\{Z_1, \dots, Z_N\})}{P(X=\{X_1, \dots, X_N\})} \quad (2.19)$$



Besarnya  $P(X = \{X_1, \dots, X_N\})$  sama untuk semua kemungkinan  $Z = \{Z_1, \dots, Z_N\}$ . Dengan demikian, nilai probabilitas pada ruas kiri dari Persamaan 2.19 sebanding dengan pembilang pada ruas kanan dari Persamaan 2.19. Hal ini dapat dituliskan ke dalam Persamaan 2.20.

$$P(Z = \{Z_1, \dots, Z_N\} | X = \{X_1, \dots, X_N\}) \propto P(X = \{X_1, \dots, X_N\} | Z = \{Z_1, \dots, Z_N\})P(Z = \{Z_1, \dots, Z_N\}) \quad (2.20)$$

$$P(X, Z) = P(X | Z)P(Z) \quad (2.21)$$

Ruas kanan Persamaan 2.20 dapat ditulis menjadi probabilitas gabungan yang *dependent* berdasarkan Persamaan 2.21, sehingga dapat dijabarkan menjadi Persamaan 2.22, 2.23, dan 2.24.

$$P(X_1, \dots, X_N, Z_1, \dots, Z_N) = P(X = \{X_1, \dots, X_N\} | Z = \{Z_1, \dots, Z_N\})P(Z = \{Z_1, \dots, Z_N\}) \quad (2.22)$$

$$P(X = \{X_1, \dots, X_N\} | Z = \{Z_1, \dots, Z_N\}) = P(X_1 | Z_1)P(X_2 | X_1, Z_1, Z_2) \dots P(X_N | X_{N-1}, \dots, X_1, Z_1, \dots, Z_N) \quad (2.23)$$

$$P(Z = \{Z_1, \dots, Z_N\}) = P(Z_1)P(Z_2 | Z_1)P(Z_3 | Z_1, Z_2) \dots P(Z_N | Z_1, \dots, Z_{N-1}) \quad (2.24)$$

Properti markov berlaku pada Persamaan 2.23 dan 2.24 sehingga masing-masing dapat dituliskan menjadi Persamaan 2.25 dan 2.26.

$$P(X = \{X_1, \dots, X_N\} | Z = \{Z_1, \dots, Z_N\}) = \prod_{n=1}^N P(X_n | Z_n) \quad (2.25)$$

$$P(Z = \{Z_1, \dots, Z_N\}) = \left( \prod_{n=2}^N P(Z_n | Z_{n-1}) \right) P(Z_1) \quad (2.26)$$

Persamaan 2.25 dan 2.26 nantinya akan disubsitusi ke Persamaan 2.22 sehingga diperoleh probabilitas gabungan yang dependen  $P(X = \{X_1, \dots, X_N\}, Z = \{Z_1, \dots, Z_N\})$  yang dituliskan dalam Persamaan 2.27 [38].

$$P(X_1, \dots, X_N, Z_1, \dots, Z_N) = \left( \prod_{n=2}^N P(Z_n | Z_{n-1}) \right) P(Z_1) \prod_{n=1}^N P(X_n | Z_n) \quad (2.27)$$

#### 2.5.4 Likelihood Hidden Markov Model (HMM)

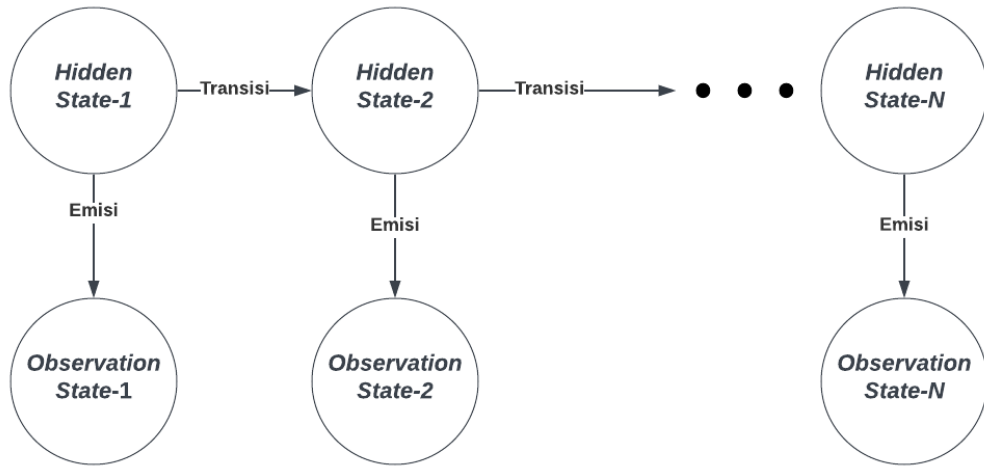
Nilai likelihood pada *Hidden Markov Model* (HMM) mengacu pada probabilitas urutan *state* observasi  $X = \{X_1, \dots, X_N\}$  diketahui parameternya  $\theta = \{A, B, \pi\}$ . *Likelihood* diperoleh dari probabilitas gabungan yang mengesampingkan *state* tersembunyi sebagai variabel laten, menjadi Persamaan 2.28 [38].

$$P(X | \theta) = \sum_Z P(X, Z | \theta) \quad (2.28)$$

Perhitungan *likelihood* dari *Hidden Markov Model* (HMM) berdasar Persamaan 2.8 mengharuskan perhitungan untuk setiap kemungkinan *state* tersembunyi dari awal sampai akhir pengamatan. Oleh karenanya, banyak penjumlahan akan meningkat secara eksponensial sepanjang model [38]. Banyaknya penjumlahan yang harus dilakukan adalah sebanyak  $S^N$  dengan  $S$  dan  $N$  masing-masing adalah banyaknya *state* tersembunyi dan panjang pengamatan. Namun, terdapat sisi positifnya yakni adanya cara untuk melakukan kalkulasi dibantu dengan variabel tambahan sehingga kompleksitasnya tereduksi [35]. Variabel tambahan tersebut diperoleh dari algoritma *forward*. Terlepas dari kompleksnya perhitungan *likelihood* dari *Hidden Markov Model* (HMM), nilai ini dijadikan acuan optimasi parameter model menggunakan algoritma Baum-Welch.

#### 2.5.5 Arsitektur Hidden Markov Model

Model ini memiliki arsitektur yang mencakup observasi dan *state* tersembunyi sepanjang pengamatan. Berikut adalah arsitektur dari *Hidden Markov Model*.



Gambar 2.1 Arsitektur *Hidden Markov Model*.

#### 2.6 Ketidaksamaan Jensen

Pertidaksamaan ini bekerja pada fungsi konveks (seperti huruf U) dan konkav (seperti huruf n). Berdasar pertidaksamaan Jensen pada fungsi konveks berlaku sebagai berikut [39].

$$f\left(\sum_{i=1}^n a_i x_i\right) \leq \sum_{i=1}^n a_i f(x_i) \quad (2.29)$$

Sebaliknya, untuk fungsi konkav berlaku

$$f\left(\sum_{i=1}^n a_i x_i\right) \geq \sum_{i=1}^n a_i f(x_i) \quad (2.30)$$

Ketidaksamaan Jensen dipakai sebagai sarana pembantu penentu sasaran optimasi dari *likelihood* model.

## 2.7 Pengali Lagrange

Pengali Lagrange menerapkan transformasi pada permasalahan optimasi dengan kendala sehingga menjadi tanpa kendala [40]. Sesuai dengan namanya, pengali Lagrange membangun fungsi Lagrange dari kombinasi linier antara fungsi tujuan dan kendala yang dikali dengan  $\lambda$  untuk setiap fungsi kendala. Untuk fungsi Lagrange dituliskan mengikuti Persamaan 2.31 berikut [41].

$$\mathcal{L}(f(x), \lambda) = f(x) - \sum_{i=1}^C \lambda_i c_i(x) \quad (2.31)$$

Fungsi Lagrange nantinya akan dicari turunannya terhadap setiap variabel pada fungsi tujuan dan  $\lambda$  terhadap setiap fungsi kendala. Teknik optimasi ini digunakan untuk kepentingan optimasi *likelihood* dari Hidden Markov Model.

## 2.8 Algoritma Viterbi

Algoritma Viterbi termasuk algoritma pemrograman dinamis yang digunakan untuk menemukan urutan hidden state dari suatu urutan observasi [42]. Algoritma ini melibatkan pemrograman dinamis yang mampu menetapkan urutan *hidden state* berdasar nilai maksimum probabilitas untuk setiap tahapan [43]. Urutan *hidden state* (Z) yang mampu memaksimalkan nilai probabilitas ruas kiri pada Persamaan 2.27 akan dicari menggunakan algoritma ini. Berikut tahapan Algoritma Viterbi [44].

### 1. Inisiasi

Pada fase pertama nilai  $\delta_t(i)$  sama dengan perkalian probabilitas inisiasi dengan emisi saat waktu pertama untuk setiap *state* tersembunyi karena tidak adanya transisi sebelum waktu pertama. Sedangkan untuk  $\psi_t(i)$  nilainya saat waktu pertama adalah 0 untuk setiap *state* tersembunyi.

$$\delta_1(i) = \pi_i B_{i[X_1]} \quad ; \quad i \leq 1 \leq S \quad (2.31)$$

$$\psi_1(i) = 0 \quad ; \quad i \leq 1 \leq S \quad (2.32)$$

### 2. Rekursi

Pada fase rekursi terjadi perulangan saat waktu ke-2 sampai ke N untuk kemudian dilanjutkan dengan terminasi.

$$\delta_n(j) = \max_i [\delta_{n-1}(i) \cdot A_{ij}] B_{j[X_n]} \quad ; \quad 1 \leq i, j \leq S \quad ; \quad 2 \leq n \leq N \quad (2.33)$$

$$\psi_n(j) = \arg \max_i [\delta_{n-1}(i) \cdot A_{ij}] \quad ; \quad 1 \leq i, j \leq S \quad ; \quad 2 \leq n \leq N \quad (2.34)$$

### 3. Terminasi

Fase ini menentukan *state* tersembunyi pengamatan terakhir yang memaksimumkan Persamaan 2.27.

$$P^* = \max_i (\delta_N(i)) \quad (2.35)$$

$$Q^* = \arg \max_i (\delta_N(i)) \quad (2.36)$$

### 4. Pelacakan/*Backtracking*

Fase ini melanjutkan pelacakan urutan *state* tersembunyi (Z) yang memaksimumkan Persamaan 2.27 dari pengamatan ke-N-1 sampai 1.

$$q_n = \psi_{n+1}(q_{n+1}) \quad ; \quad n = N - 1, \dots, 1 \quad (2.37)$$

## 2.9 Algoritma Baum-Welch

### 2.9.1 Definisi dan Hubungan dengan *Expectation Maximization* (EM)

Algoritma *forward-backward* atau dikenal juga algoritma Baum-Welch yang termasuk kasus tertentu dari algoritma *expectation-maximization* digunakan untuk pelatihan *Hidden Markov Model* (HMM) [45]. *Expectation Maximization* (EM) yakni sebuah algoritma yang akan mengeksplorasi nilai maksimum dari likelihood [46]. *Expectation Maximization* (EM) menghasilkan fungsi *loglikelihood* dengan memberikan operator ln pada kedua ruas Persamaan 2.28 sehingga menjadi Persamaan 2.37.

$$\ln (P(X | \theta)) = \ln \left( \sum_{Z \in S} P(X, Z | \theta) \right) \quad (2.38)$$

Operator ln pada ruas kanan Persamaan 2.38 sulit dijabarkan karena sifat logaritmanya. Oleh karena itu, diperlukan bantuan dari ketidaksamaan Jensen untuk mengekspektasikannya mengikuti  $P(Z | X; \hat{\theta})$ . Ketidaksamaan Jensen yang berlaku di sini adalah untuk fungsi konkaf. Dengan mengadopsi ketidaksamaan Jensen (2.30) terhadap fungsi konkaf, maka didapatkan

$$\ln \left( \sum_Z P(Z | X; \theta^s) \frac{P(X, Z | \theta)}{P(Z | X; \theta^s)} \right) \geq \sum_Z P(Z | X; \theta^s) \ln \left( \frac{P(X, Z | \theta)}{P(Z | X; \theta^s)} \right)$$

$$\ln \left( \sum_Z P(Z | X; \theta^s) \frac{P(X, Z | \theta)}{P(Z | X; \theta^s)} \right) \geq \sum_Z P(Z | X; \theta^s) (\ln (P(X, Z | \theta)) - \ln (P(Z | X; \theta^s)))$$

$$\ln \left( \sum_Z P(Z | X; \theta^s) \frac{P(X, Z | \theta)}{P(Z | X; \theta^s)} \right) \geq \sum_Z P(Z | X; \theta^s) \ln P(X, Z | \theta) - \sum_Z P(Z | X; \theta^s) \ln P(Z | X; \theta^s)$$

Memaksimumkan

$$\sum_Z P(Z | X; \theta^s) \ln P(X, Z | \theta) - \sum_Z P(Z | X; \theta^s) \ln P(Z | X; \theta^s)$$

sebanding dengan memaksimumkan nilai

$$\sum_Z P(Z | X; \theta^s) \ln P(X, Z | \theta).$$

Nilai  $P(X, Z | \theta)$  adalah bentuk model. Oleh karena itu, dengan menerapkan operator ln padanya didapatkan

$$\ln(P(X, Z | \theta)) = \sum_{i=1}^N \ln(P(x_i | z_i)) + \sum_{i=2}^N \ln(P(x_i | x_{i-1})) + \ln(P(z_1))$$

Nilai  $\ln P(X, Z | \theta)$  kemudian disubstitusi kembali ke

$$\sum_Z P(Z | X; \theta) \ln P(X, Z | \theta)$$

sehingga nilainya sama dengan:

$$\sum_z \sum_{i=1}^N \ln P(x_i | z_i) P(Z | X; \theta^s) + \sum_z \sum_{i=2}^N \ln P(z_i | z_{i-1}) P(Z | X; \theta^s) + \sum_z \ln P(z_1) P(Z | X; \theta^s).$$

Nilai  $P(Z | X; \theta^s)$  dapat ditulis menjadi  $P(Z, X | \theta^s)$  karena  $P(X)$  tidak bergantung pada parameter model. Oleh karena itu, nilai

$$\sum_Z P(Z | X; \theta^s) \ln P(X, Z | \theta)$$

dapat ditulis menjadi:

$$\sum_z \sum_{i=1}^N \ln P(x_i | z_i) P(Z, X | \theta^s) + \sum_z \sum_{i=2}^N \ln P(x_i | x_{i-1}) P(Z, X | \theta^s) + \sum_z \ln P(z_1) P(Z, X | \theta^s).$$

Nilai  $\sum_z P(Z | X; \theta^s) \ln P(X, Z | \theta)$  akan dicari  $\theta$  yang memaksimalkannya, sehingga didapatkan sebuah fungsi tujuan yang akan dioptimasi dengan pengali Lagrange, yaitu di Persamaan 2.39

$$Q(\theta, \theta^s) = \sum_z \sum_{i=1}^N \ln P(x_i | z_i) P(Z, X | \theta^s) + \sum_z \sum_{i=2}^N \ln P(z_i | z_{i-1}) P(Z, X | \theta^s) + \sum_z \ln P(z_1) P(Z, X | \theta^s) \quad (2.39)$$

Dengan ketiga fungsi kendalanya, yaitu Persamaan 2.40, 2.41, dan 2.42 [38]

$$\sum_{i \in S} \pi_i = 1 \quad (2.40)$$

$$\sum_{j \in S} P(Z_{n+1} = j | Z_n = i) = 1 \quad ; \quad 1 \leq i \leq S \quad (2.41)$$

$$\sum_{j \in M} P(X_n = j | Z_n = i) = 1 \quad ; \quad 1 \leq i \leq S \quad (2.42)$$

Dengan satu fungsi tujuan dan 3 fungsi kendala, akan dilakukan optimasi *likelihood* model menggunakan pengali Lagrange sehingga parameter model diperbaharui. Persamaan 2.39 yang sudah dioptimasi dengan pengali Lagrange dengan memerhatikan fungsi kendala di Persamaan 2.40, 2.41, dan 2.42, maka didapatkan:

### 1. Probabilitas Inisiasi:

$$P(z_1 = i | X; \theta^s)$$

### 2. Probabilitas Transisi:

$$\sum_{n=2}^{N-1} \frac{P(Z_n = i, Z_{n+1} = j | X; \theta^s)}{P(Z_n = i | X; \theta^s)}$$

### 3. Probabilitas Emisi:

$$\sum_{n=i}^N \frac{P(Z_n = i | X; \theta^s) I(X_n = j)}{P(Z_n = i | X; \theta^s)}$$

Nilai pembilang pada setiap perumusan pembaruan tiap probabilitas diperoleh dengan bantuan koefisien *forward*, *backward*, serta probabilitas transisi dan emisi.

### 2.9.2 Algoritma *Forward* dan *Backward*

Algoritma *forward* dan *backward* berperan dalam pembaharuan parameter Hidden Markov Model sehingga *likelihood*-nya meningkat. Algoritma *forward* dan *backward* perumusannya berdasar pada beberapa properti independensi kondisional berikut [38].

$$P(X | Z_n) = P(X_1, \dots, X_n | Z_n)P(X_{n+1}, \dots, X_N | Z_n) \quad (2.43)$$

$$P(X_1, \dots, X_n | X_n, Z_n) = P(X_1, \dots, X_n | Z_n) \quad (2.44)$$

$$P(X_1, \dots, X_{n-1} | Z_{n-1}, Z_n) = P(X_1, \dots, X_{n-1} | Z_{n-1}) \quad (2.45)$$

$$P(X_{n+1}, \dots, X_N | Z_n, Z_{n+1}) = P(X_{n+1}, \dots, X_N | Z_{n+1}) \quad (2.46)$$

$$P(X_{n+2}, \dots, X_N | Z_{n+1}, X_{n+1}) = P(X_{n+2}, \dots, X_N | Z_{n+1}) \quad (2.47)$$

Secara sederhana, Persamaan 2.43 menjelaskan bahwa probabilitas urutan *state* observasi bersyarat suatu *hidden state* pada waktu ke- $n$  dapat dipartisi bagian urutan *state* observasinya dengan prasyarat yang sama. Di sisi lain, Persamaan 2.44, 2.45, 2.46, serta 2.47 menjelaskan bahwa probabilitas urutan *state* observasi hanya bergantung pada *state* tersembunyi di waktu yang paling dekat langkahnya dari *state* observasi terakhir. Baik algoritma *forward* maupun *backward* menggunakan teorema Bayes di Persamaan 2.48 dengan  $P(X)$  adalah probabilitas urutan *state* observasi dengan parameter Hidden Markov Model sebelum diperbaharui [38].

$$P(Z_n | X) = \frac{P(X | Z_n)P(Z_n)}{P(X)} \quad (2.48)$$

Menggunakan sifat pada Persamaan 2.43 maka nilai  $p(X | Z_n)$  dapat dipartisi sehingga Persamaan 2.48 dapat dituliskan menjadi Persamaan 2.49 dan 2.50.

$$P(X | Z_n) = P(X_1, \dots, X_n | Z_n)P(X_{n+1}, \dots, X_N | Z_n) \quad (2.49)$$

$$P(X | Z_n) = \sum_{Z \in S} P(X, Z | Z_n) \quad (2.50)$$

Pembilang pada ruas kanan merepresentasikan probabilitas *forward* dan *backward* pada waktu ke- $n$ . Probabilitas *forward* dan *backward* masing-masing nilainya sebanding dengan ekuivalensi 2.51 dan 2.52

$$\alpha(Z_n) \equiv P(X_1, \dots, X_n, Z_n) \quad (2.51)$$

$$\beta(Z_n) \equiv P(X_{n+1}, \dots, X_N | Z_n) \quad (2.52)$$

Nilai  $\alpha(Z_n)$  yakni probabilitas gabungan dari observasi ke-1 sampai ke- $n$  dengan *state* tersembunyi ke- $n$ , sedangkan  $\beta(Z_n)$  yakni probabilitas bersyarat observasi ke- $n + 1$  sampai ke- $N$  diketahui *state* tersembunyi ke- $n$ . Nilai  $\alpha(Z_n)$  dan  $\beta(Z_n)$  masing-masing dipengaruhi oleh nilai sebelumnya dan sesudahnya. Oleh karena itu,  $\alpha(Z_n)$  dan  $\beta(Z_n)$  masing-masing dapat dituliskan mengikuti Persamaan 2.53 dan 2.54 [38].

$$a(Z_n) = \sum_{Z_{n-1} \in S} a(Z_{n-1})P(Z_n | Z_{n-1})P(X_n | Z_n) \quad (2.53)$$

$$\beta(Z_n) = \sum_{Z_{n+1} \in S} \beta(Z_{n+1})P(Z_{n+1} | Z_n)P(X_{n+1} | Z_{n+1}) \quad (2.54)$$

Untuk inisiasi probabilitas forward dapat dituliskan mengikuti Persamaan 2.55 [47]. Dan untuk inisiasi probabilitas backward mengikuti Persamaan 2.56.

$$\alpha(Z_1) = \pi_i P(X_1 | Z_1) \quad (2.55)$$

$$\beta(Z_N) = 1 \quad (2.56)$$

Untuk nilai probabilitas *forward* maupun *backward* waktu ke-2 sampai ke- $N$  dijabarkan berdasar Persamaan 2.43 sampai 2.48. Sesuai yang disebutkan sebelumnya, koefisien *forward* dapat digunakan untuk menghitung *likelihood* dari model. Peran koefisien *forward* terhadap perhitungan *likelihood* adalah sebagai Persamaan 2.57 berikut [38].

$$P(X | \theta) = \sum_{Z_N \in S} \alpha(Z_N) \quad (2.57)$$

Sementara itu, algoritma *forward* dan *backward* mengambil andil penting pada proses pembaharuan parameter hasil optimasi oleh pengali Lagrange. Peranannya adalah merepresentasikan bentuk  $P(Z_{t+1} = j, Z_t = i, X | \theta^s)$  dan  $P(Z_t = i, X | \theta^s)$  yang dapat dituliskan dalam notasi perkalian antar probabilitas *forward*, *backward*, emisi, dan transisi. Berdasarkan properti independensi yang dituliskan di Persamaan 2.43 sampai 2.46, maka untuk  $P(Z_{t+1} = j, Z_t = i | X; \theta^s)$  dijabarkan menjadi

$$P(Z_t = i, Z_{t+1} = j, X | \theta^s) = P(Z_t = i, Z_{t+1} = j, X_1, \dots, X_N | \theta^s)$$

$$P(Z_t = i, Z_{t+1} = j, X_1, \dots, X_N | \theta^s) = P(Z_{t+1} = j, X_{t+1}, \dots, X_N | Z_t = i; \theta^s)P(Z_t = i, X_1, \dots, X_t | \theta^s)$$



$$= P(X_{t+1}, \dots, X_N | Z_{t+1} = j; \theta^s) P(Z_{t+1} = j | Z_t = i; \theta^s) P(Z_t = i, X_1, \dots, X_t | \theta^s)$$

$$= P(X_{t+2}, \dots, X_N | Z_{t+1} = j; \theta^s) P(X_{t+1} | Z_{t+1} = j; \theta^s) P(Z_{t+1} = j | Z_t = i; \theta^s) P(Z_t = i, X_1, \dots, X_t | \theta^s).$$

$$= \alpha(Z_n = i) P(Z_{n+1} = j | Z_n = i) \beta_{n+1}(j) p(X_{n+1} | Z_{n+1})$$

Sedangkan untuk  $P(Z_t = i, X | \theta^s)$  dijabarkan menjadi

$$P(Z_t = i, O | \theta^s) = P(Z_t = i, O_1, \dots, O_N | \theta^s)$$

$$P(Z_t = i, O_1, \dots, O_N | \theta^s) = P(O_{t+1}, \dots, O_N | Z_t = i; \theta^s) P(Z_t = i, O_1, \dots, O_N | \theta^s)$$

$$= \alpha(Z_n = i) \beta(Z_n = i)$$

Penjabaran tersebut memberikan bentuk probabilitas  $\xi_n(i, j)$  dan  $\gamma_n(i)$  yang digunakan pada hasil optimasi pengali Lagrange Bentuk ini kemudian berperan dalam pembaruan parameter model, sehingga diperoleh Persamaan 2.58 dan 2.59 [38].

$$\xi_n(i, j) = \frac{\alpha(Z_n = i) P(Z_{n+1} = j | Z_n = i) \beta_{n+1}(j) p(X_{n+1} | Z_{n+1} = j)}{P(X | \theta)} \quad (2.58)$$

$$\gamma_n(i) = \frac{\alpha(Z_n = i) \beta(Z_n = i)}{P(X | \theta)} \quad (2.59)$$

Nilai  $\xi_n(i, j)$  adalah probabilitas *hidden state* waktu ke- $n$  adalah  $i$  dan ke- $n + 1$  adalah  $j$  bersyarat urutan observasi dan parameter model. Sedangkan untuk  $\gamma_n(i)$  adalah probabilitas *hidden state* waktu ke- $n$  adalah  $i$  bersyarat urutan observasi dan parameter model [47]. Persamaan 2.58 dan 2.59 nantinya dipadukan dalam persamaan pembaharuan parameter model hasil optimasi oleh pengali Lagrange. Oleh karenanya, ketiga parameter model terbaru dapat dituliskan mengikuti Persamaan 2.60 sampai 2.62.

$$\pi_i^* = \gamma_1(i) \quad (2.60)$$

$$A_{ij}^* = \frac{\sum_{n=1}^{N-1} \xi_n(i, j)}{\sum_{n=1}^{N-1} \gamma_n(i)} \quad (2.61)$$

$$B_{iq}^* = \frac{\sum_{n=1}^N \gamma_n(i) I(X_n, M_q)}{\sum_{n=1}^N \gamma_n(i)} \quad (2.62)$$

Pada Persamaan 2.62 terdapat sebuah fungsi, yaitu fungsi  $I$ . Fungsi  $I$  mengembalikan nilai 1 apabila state observasi ke- $n$  adalah sama dengan *state* observasi  $q$ . Secara matematis fungsi  $I$  dapat dituliskan mengikuti Persamaan 2.63.

$$I(X_n, M_q) = \begin{cases} 1, & X_n = M_q \\ 0, & X_n \neq M_q \end{cases} \quad (2.63)$$

## 2.10 Evaluasi Model

Pemodelan Hidden Markov Model yang digunakan sebagai pendekatan prediksi memerlukan pengukuran untuk menilai kinerjanya terhadap data uji. Penelitian ini menggunakan MSE, RMSE, dan MAPE. Rumus MSE, RMSE, dan MAPE secara berurutan dituliskan pada Persamaan 2.64, 2.65, dan 2.66 berikut [48].

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_n - \hat{y}_n)^2 \quad (2.64)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_n - \hat{y}_n)^2} \quad (2.65)$$

$$\text{MAPE} = \frac{1}{N} \sum_{i=1}^N \frac{|y_n - \hat{y}_n|}{|y_n|} \quad (2.66)$$

MSE digunakan untuk memberikan penalti lebih tinggi terhadap kesalahan prediksi sehingga sensitif terhadap penciran (data yang terlampau rendah atau tinggi dari sebaran). Kesalahan prediksi dengan MSE diatur menjadi besar karena melakukan pengkuadratan atas kesalahan tersebut [49]. Sama halnya dengan MSE, RMSE juga memberikan pengkuadratan atas kesalahan prediksi. Namun, RMSE memberikan operasi akar kuadrat pada akhirnya. Pemberian akar kuadrat ini menjadikan besarnya kesalahan prediksi relatif lebih mudah diinterpretasikan dan lebih mendekati besar kesalahan sebenarnya. Beda halnya dengan MAPE, pengukuran dengan MAPE tidak melakukan operasi pengkuadratan maupun akar kuadrat terhadap kesalahan prediksi. MAPE mengukur rerata persentase kesalahan relatif terhadap data aktual. Besarnya nilai MAPE dikelompokkan menjadi interval berikut [50].

**Tabel 2.2** *Range* Nilai MAPE.

<b>Range MAPE</b>	<b>Arti</b>
< 10%	Kemampuan Model Sangat Baik
10 - 20%	Kemampuan Model Baik
20 - 50%	Kemampuan Model Layak
> 50%	Kemampuan Model Buruk

## BAB III

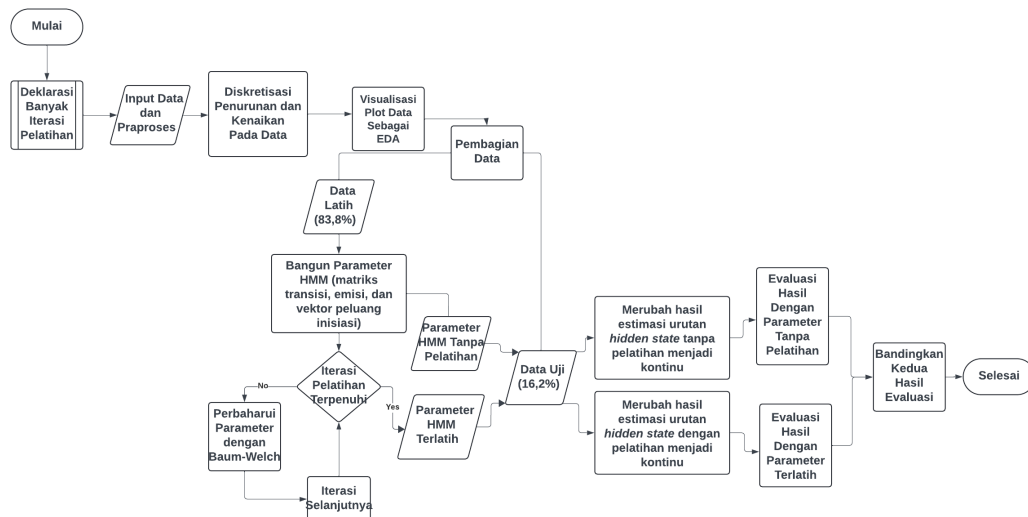
### Metode Penelitian

#### 3.1 Deskripsi Data

Penelitian ini menggunakan metode kuantitatif dengan data yang digunakan adalah kurs jual rupiah terhadap dolar Amerika Serikat (Januari 2019—Agustus 2024) dan persentase inflasi di Indonesia (Januari 2019—Agustus 2024). Kedua data diperoleh dari laman Bank Indonesia. Variabel pada penelitian ini adalah data bulanan nilai kurs jual rupiah terhadap dolar Amerika Serikat dan data bulanan persentase inflasi di Indonesia. Data bulanan kurs jual rupiah terhadap dolar Amerika Serikat adalah variabel dependen, sedangkan data bulanan persentase inflasi di Indonesia adalah variabel independen. Kurs dan persentase inflasi bersifat kontinu karena dapat berupa bilangan desimal.

#### 3.2 Tahapan Penelitian

Penelitian ini menerapkan metode stokastik menggunakan model markov tersembunyi yang dilatih dengan algoritma Baum-Welch sebagai bentuk optimasi. Seperti yang ditunjukkan pada diagram alir di Gambar 3.1 data melalui penetapan iterasi pelatihan, input dan praproses, dikretisasi pola kenaikan-penurunan, dan pembagian data menjadi data latih dan uji. Selanjutnya, akan dilakukan estimasi terhadap data latih dengan model sebelum dan sesudah pelatihan dengan algoritma Baum-Welch untuk nanti dibandingkan hasilnya.



Gambar 3.1 diagram Alir Penelitian.

Dimulai dari penetapan batas iterasi. Hal ini menjadi krusial mengingat banyaknya iterasi berbanding lurus dengan *likelihood* model. Namun, akibat iterasi yang terlampaui besar, tidak jarang ditemukan nilai parameter yang sangat kecil dibanding dengan parameter lainnya. Penelitian ini menetapkan batas iterasi

sebanyak 10 kali supaya dapat meningkatkan *likelihood* model sembari mempertahankan nilai parameter agar tidak terlalu kecil.

Tahap input dan praproses di penelitian ini mencakup pemasukan, penyeragaman format, dan pengubahan tipe data. Kedua data dimasukkan ke aplikasi *R Studio*. Selanjutnya data kurs jual diperbaiki format tanggalnya agar seragam, yakni bulan-tahun. Untuk data inflasi diperbaiki juga formatnya kemudian dilanjutkan merubah tipe datanya dari *string* menjadi numerik.

Baik data kurs maupun inflasi yang sudah dilakukan praproses dilanjutkan dengan diskritisasi. Data dilakukan diskritisasi berdasarkan pola perubahannya. Apabila nilai sebelumnya lebih rendah dari nilai saat ini maka kondisi data saat ini mengalami kenaikan. Begitu juga sebaliknya, apabila nilai sebelumnya lebih tinggi dari nilai saat ini maka kondisi data saat ini mengalami penurunan.

Visualisasi terhadap data setelah proses diskretisasi ditujukan untuk *Exploratory Data Analysis* (EDA). Visualisasi yang dipakai berupa plot terhadap data. Visualisasi ini juga mempertegas kelebihan model, yakni data yang memiliki data yang terlampaui besar atau kecil beserta variasi pola lama menetapnya *state* tersembunyi dapat dimodelkan olehnya. Selain itu, melalui visualisasi data dapat ditentukan banyak *state* tersembunyi dan *state* observasi.

Data inflasi dan kurs rupiah terhadap dolar Amerika Serikat dibagi menjadi data latih dan uji. Pembagian data latih dan uji masing-masing dalam interval Januari 2019—September 2023 dan Oktober 2023—Agustus 2024. Dari data latih akan dibangun ketiga parameter HMM (matriks transisi, emisi, dan peluang inisiasi).

Parameter model selanjutnya dilatih sebanyak iterasi yang ditentukan dengan algoritma Baum-Welch, sebagai bentuk optimasi dan penyesuaian terhadap urutan observasi. Parameter yang sudah dilatih nantinya digunakan untuk mengestimasi urutan hidden state. Di sisi lain, dilakukan juga estimasi urutan *state* tersembunyi dengan parameter yang tidak dilatih. Saat keduanya selesai melakukan estimasi terhadap urutan *state* tersembunyi maka dilanjutkan dengan merubah urutan *state* tersembunyi tersebut kembali ke nilai kontinu.

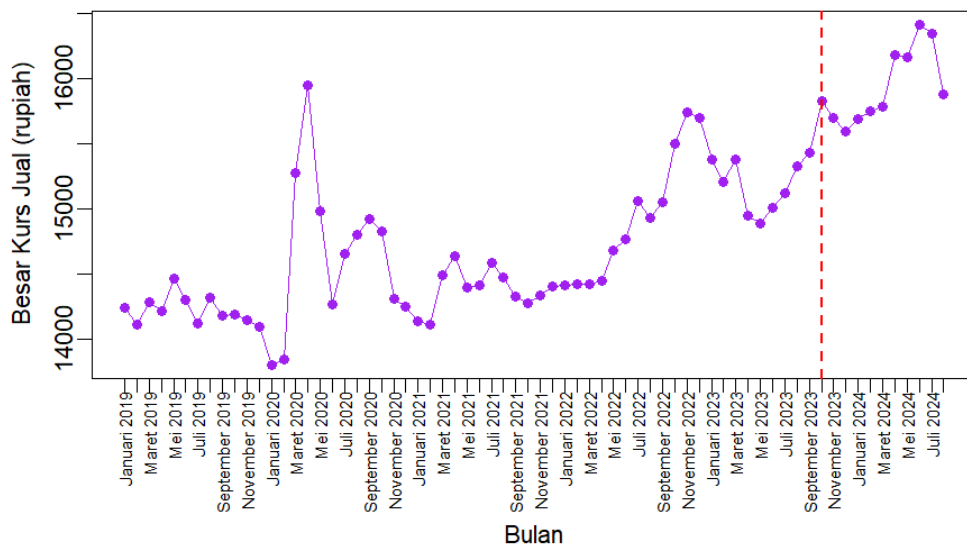
Perubahan urutan hidden state ke nilai kontinu dilakukan dengan menambah atau mengurangi nilai sebelumnya berdasarkan urutan hidden state yang diestimasi dengan nilai rata-rata perubahan setiap *state* tersembunyi. Selanjutnya, dilakukan proses evaluasi model dengan MSE, RMSE, dan MAPE terhadap kinerja model HMM baik tanpa maupun dengan pelatihan. Sampai pada tahap akhir penelitian ini, kedua model tersebut dibandingkan antar satu sama lain.

## BAB IV


### Hasil dan Pembahasan

Data bulanan kurs rupiah terhadap dolar Amerika Serikat dan inflasi di Indonesia dari Januari 2019 sampai dengan September 2023 dijadikan data latih yang membangun parameter model. Dan untuk sisanya, dari Oktober 2023 sampai Agustus 2024 akan dijadikan data uji. Berikut adalah plot pembagian data latih dan uji untuk kurs dan inflasi masing-masing pada Gambar 4.1 dan 4.2 berikut.

**Plot Kurs Perbulan**



**Gambar 4.1** Plot Data Kurs Dolar Amerika Serikat Terhadap Rupiah.



**Gambar 4.2** Plot Data Inflasi Di Indonesia.

Dari gambar 4.1 dan 4.2, data latih dan uji dipisahkan oleh garis merah vertikal. Baik data uji maupun latih, keduanya sudah dilakukan diskritisasi pola kenaikan atau penurunan pada inflasi dan juga kurs. Berdasarkan hasil diskritisasi, didapatkan pola kenaikan/penurunan kurs rupiah terhadap dolar Amerika Serikat dan inflasi di Indonesia pada Tabel 4.1 berikut.

**Tabel 4.1** Tabel Kurs dan Inflasi

Bulan-Tahun	Kurs (Rp)	Kondisi Kurs	Inflasi (%)	Kondisi Inflasi
Januari-2019	14233.91	Nilai Awal	2.82	Nilai Awal
Februari-2019	14105.37	turun	2.57	turun
Maret-2019	14282.10	naik	2.48	turun
⋮	⋮	⋮	⋮	⋮
Juni 2024	16411.04	naik	2.51	turun
Juli 2024	16342.96	turun	2.13	turun
Agustus 2024	15872.15	turun	2.12	turun

#### 4.1 Parameter dan *Likelihood* Model Sesudah Serta Sebelum Pelatihan Oleh Algoritma Baum-Welch

Parameter model yang dibangun dari data latih menjadikan mereka sebagai inisiasi parameter saat melakukan pelatihan menggunakan algoritma Baum-Welch. Parameter ini akan terus diperbaharui sampai iterasi pelatihan terpenuhi, yaitu sebanyak 10 kali.

#### 4.1.1 Parameter Model Sebelum Pelatihan

##### 1. Probabilitas Transisi

Parameter ini berisikan probabilitas untuk setiap kemungkinan transisi kondisi kurs rupiah terhadap dolar Amerika Serikat sebagai *state* tersembunyi dari suatu bulan ke bulan selanjutnya. Kemungkinan transisi kondisi kurs rupiah terhadap dolar Amerika Serikat (*state* tersembunyi) tersebut adalah naik ke naik, naik ke turun, turun ke naik, dan turun ke turun. Setiap kemungkinan transisi, nilai probabilitasnya didapat menggunakan Persamaan 2.9. Dari Tabel 4.1 didapatkan banyaknya setiap kemungkinan transisi kondisi kurs rupiah terhadap dolar Amerika Serikat sebagai berikut pada Tabel 4.2.

**Tabel 4.2** Transisi antara bulan ke- $n$  dan bulan ke- $n + 1$

Bulan ke- $n + 1$			
Bulan ke- $n$	Naik	Turun	Total
Naik	17	12	29
Turun	13	13	26
Total	30	25	55

Pada Tabel 4.2 terdapat banyaknya transisi kurs rupiah terhadap dolar Amerika Serikat skala perbulan. Nilai 17 Pada Tabel 4.2 meurujuk pada banyaknya transisi yang terjadi apabila diketahui suatu bulan kurs rupiah terhadap dolar Amerika Serikat sedang mengalami kenaikan kemudian di bulan selanjutnya juga mengalami kenaikan ( $K_{naik,naik}$ ). Nilai 12 Pada Tabel 4.2 meurujuk pada banyaknya transisi yang terjadi apabila diketahui suatu bulan kurs rupiah terhadap dolar Amerika Serikat sedang mengalami kenaikan kemudian di bulan selanjutnya mengalami penurunan ( $K_{naik,turun}$ ). Nilai 13 Pada Tabel 4.2 meurujuk pada banyaknya transisi yang terjadi apabila diketahui suatu bulan kurs rupiah terhadap dolar Amerika Serikat sedang mengalami penurunan kemudian di bulan selanjutnya mengalami kenaikan ( $K_{turun,naik}$ ). Nilai 13 Pada Tabel 4.2 meurujuk pada banyaknya transisi yang terjadi apabila diketahui suatu bulan kurs rupiah terhadap dolar Amerika Serikat sedang mengalami penurunan kemudian di bulan selanjutnya juga mengalami penurunan ( $K_{turun,turun}$ ). Pada Tabel 4.2 juga terdapat total banyaknya transisi kurs rupiah terhadap dolar Amerika Serikat ke kondisi naik dan turun masing-masing sebanyak 30 dan 25. Untuk banyaknya transisi kurs rupiah terhadap dolar Amerika Serikat yang diawali oleh kondisi naik dan turun masing-masing sebanyak 29 dan 26.

Dari Tabel 4.2 nantinya nilai-nilai transisi akan disubstitusi pada Persamaan 2.9 yang diterapkan pada matriks probabilitas transisi kondisi kurs rupiah terhadap dolar Amerika Serikat. Berikut adalah matriks  $A$  yang setiap entrinya merupakan bentuk Persamaan 2.9 yang digunakan untuk menghitung probabilitas transisi kondisi kurs rupiah terhadap dolar Amerika Serikat.



$$\mathbf{A} = \begin{bmatrix} \frac{K_{naik,naik}}{\sum_{j \in S} K_{naik,j}} & \frac{K_{naik,turun}}{\sum_{j \in S} K_{naik,j}} \\ \frac{K_{turun,naik}}{\sum_{j \in S} K_{turun,j}} & \frac{K_{turun,turun}}{\sum_{j \in S} K_{turun,j}} \end{bmatrix}$$

Dengan mensubstitusi banyaknya transisi kurs rupiah terhadap dolar Amerika Serikat ke matriks  $A$ , maka didapatkan

$$\mathbf{A} = \begin{bmatrix} 0.586 & 0.413 \\ 0.5 & 0.5 \end{bmatrix}$$

Entri  $A_{11}$  memuat nilai probabilitas transisi *state* tersembunyi dari naik ke naik, artinya jika diketahui pada suatu bulan kondisi kurs rupiah terhadap dolar Amerika Serikat sedang mengalami kenaikan, maka probabilitas di bulan selanjutnya akan mengalami kenaikan juga adalah sebesar 0.586. Entri  $A_{12}$  memuat nilai probabilitas transisi *state* tersembunyi dari naik ke turun, artinya jika diketahui pada suatu bulan kondisi kurs rupiah terhadap dolar Amerika Serikat sedang mengalami kenaikan, maka probabilitas di bulan selanjutnya akan mengalami penurunan adalah sebesar 0.413. Entri  $A_{21}$  memuat nilai probabilitas transisi *state* tersembunyi dari turun ke naik, artinya jika diketahui pada suatu bulan kondisi kurs rupiah terhadap dolar Amerika Serikat sedang mengalami penurunan, maka probabilitas di bulan selanjutnya akan mengalami kenaikan adalah sebesar 0.5. Entri  $A_{22}$  memuat nilai probabilitas transisi *state* tersembunyi dari turun ke turun, artinya jika diketahui pada suatu bulan kondisi kurs rupiah terhadap dolar Amerika Serikat sedang mengalami penurunan, maka probabilitas di bulan selanjutnya akan mengalami penurunan juga adalah sebesar 0.5.

## 2. Probabilitas Emisi

Parameter ini berisikan probabilitas setiap kemungkinan pasangan kondisi kurs rupiah terhadap dolar Amerika Serikat sebagai *state* tersembunyi dengan kondisi besar inflasi di Indonesia sebagai *state* observasi pada waktu yang sama. Dengan banyaknya *state* tersembunyi yang sama dengan banyaknya *state* observasi adalah 2, maka ada 4 kemungkinan pasangan. Kemungkinan pasangan tersebut adalah naik dengan naik, naik dengan turun, turun dengan naik, dan turun dengan turun. Setiap kemungkinan pasangan, nilai probabilitasnya didapat menggunakan Persamaan 2.14. Dari Tabel 4.1 didapatkan banyaknya setiap kemungkinan emisi kondisi kurs rupiah terhadap dolar Amerika Serikat ke kondisi inflasi di Indonesia sebagai berikut pada Tabel 4.3.

Pada Tabel 4.3 terdapat banyaknya emisi kondisi kurs rupiah terhadap dolar Amerika Serikat ke inflasi di Indonesia. Nilai 15 pada Tabel 4.3 di baris dan kolom pertama merujuk pada jumlah bulan di mana kurs rupiah terhadap dolar Amerika Serikat dan inflasi di Indonesia mengalami kenaikan secara bersamaan ( $L_{naik,naik}$ ). Nilai 15 pada Tabel 4.3 di baris pertama kolom ke-2 merujuk pada jumlah bulan di mana kurs rupiah terhadap dolar Amerika

**Tabel 4.3** Hubungan antara kurs dan inflasi

Inflasi			
Kurs	Naik	Turun	Total
Naik	15	15	30
Turun	12	14	26
Total	27	29	56

Serikat mengalami kenaikan, sedangkan inflasi di Indonesia mengalami penurunan ( $L_{naik,turun}$ ). Nilai 12 pada Tabel 4.3 merujuk pada jumlah bulan di mana kurs rupiah terhadap dolar Amerika Serikat mengalami penurunan, sedangkan inflasi di Indonesia mengalami kenaikan ( $L_{turun,naik}$ ). Nilai 14 pada Tabel 4.3 merujuk pada jumlah bulan di mana kurs rupiah terhadap dolar Amerika Serikat dan inflasi di Indonesia mengalami penurunan secara bersamaan ( $L_{turun,turun}$ ). Pada Tabel 4.3 juga terdapat banyaknya bulan yang mengalami kondisi kenaikan dan penurunan kurs rupiah terhadap dolar Amerika Serikat masing-masing sebesar 30 dan 26. Pada Tabel 4.3 juga terdapat banyaknya bulan yang mengalami kondisi kenaikan dan penurunan inflasi di Indonesia masing-masing sebesar 27 dan 29.

Dari Tabel 4.3 nantinya nilai-nilai emisi akan disubstitusi pada Persamaan 2.14 yang diterapkan pada matriks probabilitas emisi kondisi kurs rupiah terhadap dolar Amerika Serikat ke inflasi di Indonesia. Berikut adalah matriks  $B$  yang setiap entrinya merupakan bentuk Persamaan 2.14 yang digunakan untuk menghitung probabilitas emisi kondisi kurs rupiah terhadap dolar Amerika Serikat ke inflasi di Indonesia.

$$\mathbf{B} = \begin{bmatrix} \frac{L_{naik,naik}}{\sum_{q \in M} L_{naik,q}} & \frac{L_{naik,turun}}{\sum_{q \in M} L_{naik,q}} \\ \frac{L_{turun,naik}}{\sum_{q \in M} L_{turun,q}} & \frac{L_{turun,turun}}{\sum_{q \in M} L_{turun,q}} \end{bmatrix}$$

Berdasarkan data latih (Januari 2019 - September 2023) yang berada di Tabel 4.1, diperoleh nilai  $L_{naik,naik}$ ,  $L_{naik,turun}$ ,  $L_{turun,naik}$ , dan  $L_{turun,turun}$  masing-masing sebanyak 15, 15, 12, dan 14. Nilai-nilai ini akan disubstitusi ke matriks probabilitas emisi, sebagai berikut.

$$\mathbf{B} = \begin{bmatrix} 0.5 & 0.5 \\ 0.461 & 0.538 \end{bmatrix}$$

Di entri  $B_{11}$  merujuk pada probabilitas kondisi inflasi di Indonesia sedang mengalami kenaikan, jika diketahui kurs rupiah terhadap dolar Amerika Serikat juga sedang mengalami kenaikan di waktu yang sama adalah sebesar 0.5. Di entri  $B_{12}$  merujuk pada probabilitas kondisi inflasi di Indonesia sedang mengalami kenaikan, jika diketahui kurs rupiah terhadap dolar Amerika Serikat sedang mengalami penurunan di waktu yang sama adalah sebesar 0.5. Di entri  $B_{21}$  merujuk pada probabilitas kondisi inflasi di Indonesia sedang mengalami kenaikan, jika diketahui kurs rupiah terhadap dolar Amerika Serikat sedang mengalami penurunan di waktu yang sama

adalah sebesar 0.461. Di entri  $B_{22}$  merujuk pada probabilitas kondisi inflasi di Indonesia sedang mengalami penurunan, jika diketahui kurs rupiah terhadap dolar Amerika Serikat juga sedang mengalami penurunan di waktu yang sama adalah sebesar 0.538. Sehingga matriks  $B$  merupakan parameter yang mengatur emisi dari *state* tersembunyi ke *state* observasi.

### 3. Probabilitas Inisiasi

Parameter ini merupakan probabilitas setiap kondisi kurs rupiah terhadap dolar Amerika Serikat terjadi di awal pengamatan. Probabilitas ini dihitung dengan menerapkan Persamaan 2.17 terhadap data latih kurs rupiah terhadap dolar Amerika Serikat yang berada di Tabel 4.1. Probabilitas ini dihitung dengan banyaknya bulan yang terjadi kenaikan dan penurunan kurs rupiah terhadap dolar Amerika Serikat. Berikut adalah Tabel 4.4 yang berisi banyaknya bulan yang mengalami kondisi tersebut.

**Tabel 4.4** Jumlah Bulan berdasarkan Kondisi Kurs

Kurs	Banyak Bulan
Naik	30
Turun	26

Pada Tabel 4.4 nilai 30 merujuk pada banyaknya bulan yang di mana mengalami kenaikan kurs rupiah terhadap dolar Amerika Serikat ( $F_{naik}$ ). Nilai 26 merujuk pada banyaknya bulan yang di mana mengalami penurunan kurs rupiah terhadap dolar Amerika Serikat ( $F_{turun}$ ). Berikut adalah matriks  $\pi$  yang setiap entrinya berisi bentuk Persamaan 2.17 yang digunakan untuk menghitung probabilitas inisiasi kondisi kurs rupiah terhadap dolar Amerika Serikat.

$$\pi = \begin{bmatrix} \frac{F_{naik}}{F_{naik} + F_{turun}} & \frac{F_{turun}}{F_{naik} + F_{turun}} \end{bmatrix}$$

Dengan menyelesaikan perhitungan serta substitusi nilai-nilai pada tabel 4.4, maka didapatkan setiap nilai probabilitas inisiasi sebagai berikut.

$$\pi = \begin{bmatrix} 0.535 & 0.464 \end{bmatrix}$$

Nilai 0.535 di entri pertama, dan 0.464 di entri kedua, masing-masing merujuk pada probabilitas terjadinya kenaikan, dan penurunan, pada kurs rupiah terhadap dolar Amerika Serikat di awal pengamatan.

#### 4.1.2 Parameter dan Likelihood Model Setelah Pelatihan

Berorientasi pada optimasi probabilitas terjadinya urutan kondisi inflasi sepanjang data uji bersyarat parameter model (*likelihood*), ketiga parameter model akan diperbaharui, sehingga probabilitas terjadinya urutan kondisi inflasi sepanjang data uji bersyarat parameter model meningkat. Nilai *likelihood* yang besar menunjukkan kecocokan parameter yang lebih baik terhadap urutan kondisi inflasi yang terjadi sepanjang data uji. Untuk meningkatkan kecocokan tersebut

digunakan algoritma Baum-Welch. Algoritma Baum-Welch bekerja dengan memperbaharui parameter model secara iteratif. Algoritma Baum-Welch diharapkan membantu meningkatkan kemampuan model dalam memprediksi kemungkinan urutan kondisi kurs rupiah terhadap dolar Amerika Serikat berdasarkan observasi inflasi di Indonesia sepanjang Oktober 2023 sampai Agustus 2024. Sebagai bagian dari algoritma *Expectation Maximization* (EM), algoritma Baum-Welch menjamin adanya kenaikan pada *likelihood* model [51]. Di sisi lain, algoritma Baum-Welch menjamin konvergensi *likelihood* pada lokal optimum. Jaminan konvergensi lokal optimum menjadikan algoritma Baum-Welch juga menghasilkan nilai optimum skala lokal [52]. Untuk mencapai konvergensi tersebut tentunya memerlukan komputasi yang mahal. Untuk mengatasi hal tersebut dilakukan pembatasan sebanyak 10 iterasi. Pemilihan pembatasan iterasi ini relatif tidak terlalu besar, mengingat banyaknya jenis kondisi kurs rupiah terhadap dolar Amerika Serikat (*state* tersembunyi) dan inflasi di Indonesia (*state* observasi) masing-masing sebanyak 2. Bukan hanya itu, panjang observasi yang dilakukan juga relatif tidak begitu panjang yakni sebanyak 11 pengamatan.

Sesuai dengan nama lainnya, algoritma ini membutuhkan koefisien *forward* ( $\alpha(Z_n = i)$ ) dan *backward* ( $\beta(Z_n = i)$ ) untuk setiap *state* tersembunyi di waktu pengamatan awal ( $n = 1$ ) sampai akhir ( $n = 11$ ). Nilai  $\alpha(Z_n = i)$  mengacu pada probabilitas terjadinya kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "i" pada bulan ke- $n$  (rentang Oktober 2023 - Agustus 2024) dengan kondisi inflasi sepanjang observasi dari bulan Oktober 2023 sampai bulan ke- $n$ . Sedangkan nilai  $\beta(Z_n = i)$  mengacu pada probabilitas terjadinya kondisi inflasi pada bulan ke- $n + 1$  sampai akhir pengamatan (rentang Oktober 2023 - Agustus 2024), jika diketahui pada bulan ke- $n$  kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "i". Kedua koefisien ini nantinya akan berkontribusi membangun  $\xi_t(i, j)$  serta  $\gamma_t(i)$ , yang digunakan sebagai formula pembaruan parameter, seperti yang ditunjukkan melalui Persamaan 2.60 sampai 2.62.

Inisiasi perhitungan  $\alpha(Z_n = i)$  dimulai dari waktu pengamatan pertama di bulan Oktober 2023 ( $n = 1$ ) untuk setiap kondisi rupiah terhadap dolar Amerika Serikat, yang mana proses ini menggunakan Persamaan 2.55 dengan melakukan multiplikasi setiap probabilitas inisiasi kondisi rupiah terhadap dolar Amerika Serikat dengan probabilitas emisi untuk kondisi inflasi yang terjadi di Oktober 2023 ( $n = 1$ ). Selanjutnya, untuk pengamatan November 2023 ( $n = 2$ ) sampai Agustus 2024 ( $n = 11$ ) besarnya  $\alpha(Z_n = i)$  dicari secara iteratif menggunakan Persamaan 2.53 untuk setiap kondisi kurs rupiah terhadap dolar Amerika Serikat (naik atau turun). Berbeda halnya dengan inisiasi perhitungan  $\alpha(Z_n = i)$  yang dimulai dari pengamatan pertama ( $n = 1$ ), nilai  $\beta(Z_n = i)$  diinisiasi dari pengamatan terakhir tepatnya di bulan Agustus 2024 ( $n = 11$ ) untuk setiap kondisi rupiah terhadap dolar Amerika Serikat, yang mana nilai ini mengikuti Persamaan 2.56. Selanjutnya, untuk pengamatan Juli 2024 ( $n = 10$ ) sampai pengamatan pertama di Oktober 2023 ( $n = 1$ ) besarnya  $\beta(Z_n = i)$  dicari secara iteratif menggunakan Persamaan 2.54. Untuk iterasi pertama, algoritma Baum-Welch menggunakan nilai koefisien *forward* dan *backward* yang diperoleh dari probabilitas inisiasi, emisi, dan transisi yang dimiliki model saat pertama kali

dibangun. Selanjutnya, untuk iterasi ke-2, 3, dan seterusnya algoritma Baum-Welch akan menggunakan nilai koefisien *forward* dan *backward* yang diperoleh dari probabilitas inisiasi, emisi, dan transisi yang dimiliki model saat setelah menyelesaikan iterasi sebelumnya. Berikut adalah Tabel 4.2 yang berisi nilai dari koefisien *forward* dan *backward* yang dipakai di setiap iterasi pelatihan.

**Tabel 4.5** Tabel Nilai  $\alpha$  dan  $\beta$  yang digunakan Sepanjang Iterasi Pelatihan

Iterasi	$\alpha$		$\beta$	
1	0.2678571500	0.2142857255	0.001119369	0.001112359
	0.1320812862	0.1006063022	0.002306035	0.002322015
	0.0638650562	0.0565155599	0.004458664	0.004484440
	0.0328479583	0.0294456053	0.008669883	0.008605886
	0.0169892512	0.0130684909	0.017954134	0.017841859
	0.0082467309	0.0062604376	0.036986107	0.037246437
	0.0039822547	0.0035229701	0.071473043	0.071976087
	0.0020479551	0.0018357846	0.138116867	0.139088385
	0.0010592089	0.0009505579	0.266907159	0.268771660
	0.0005480973	0.0004919235	0.515915103	0.519230750
	0.0002836301	0.0002545634	1.000000000	1.000000000
2	0.2113926627	0.1528108506	0.002040033	0.002024230
	0.0749454924	0.0575132550	0.005578756	0.005606874
	0.0444725787	0.0398174537	0.008769748	0.008804152
	0.0281269485	0.0255205592	0.013862684	0.013740186
	0.0109404921	0.0085618170	0.038102999	0.037808174
	0.0040006989	0.0030910489	0.104193590	0.104729834
	0.0023803941	0.0021324700	0.163704387	0.164546866
	0.0015058735	0.0013664006	0.257205482	0.258528353
	0.0009579410	0.0008701844	0.404116732	0.406180805
	0.0006096765	0.0005538779	0.635053877	0.638037387
	0.0003880418	0.0003525305	1.000000000	1.000000000
3	0.2226268080	0.1427125019	0.002042294	0.002023501
	0.0757160649	0.0571595940	0.005580677	0.005614131
	0.0442094303	0.0403573477	0.008771765	0.008812612
	0.0279219575	0.0259134472	0.013879821	0.013734050
	0.0109943688	0.0085685071	0.038156624	0.037805928
	0.0040234611	0.0030883645	0.104259699	0.104898084
	0.0023646296	0.0021616913	0.163771154	0.164773875
	0.0014943972	0.0013870748	0.257252184	0.258826293
	0.0009507491	0.0008836450	0.404100052	0.406555353
	0.0006052302	0.0005625784	0.634909927	0.638456192
	0.0003852987	0.0003581496	1.000000000	1.000000000

Iterasi	$\alpha$		$\beta$	
4	0.2376218728	0.1298846704	0.002047132	0.002021746
	0.0774196515	0.0562602490	0.005584180	0.005629409
	0.0438304892	0.0412667066	0.008775463	0.008830469
	0.0276067882	0.0265899976	0.013917411	0.013720279
	0.0111619480	0.0085164616	0.038269041	0.037795060
	0.0040918825	0.0030586334	0.104383299	0.105247339
	0.0023418233	0.0022102475	0.163890012	0.165246546
	0.0014766087	0.0014225320	0.257320850	0.259449363
	0.0009396255	0.0009068617	0.404025699	0.407343683
	0.0005984101	0.0005776372	0.634560413	0.639345727
	0.0003811312	0.0003679061	1.000000000	1.000000000
5	0.2589795498	0.1130395761	0.002056206	0.002019482
	0.0804858100	0.0548762866	0.005593889	0.005659421
	0.0434038675	0.0428006007	0.008786219	0.008865314
	0.0272143291	0.0277386624	0.013988779	0.013702947
	0.0114906672	0.0084281559	0.038485314	0.037798865
	0.0042236976	0.0030075150	0.104688240	0.105943014
	0.0023145575	0.0022911176	0.164207771	0.166175814
	0.0014537500	0.0014822723	0.257567543	0.260652405
	0.0009255534	0.0009462500	0.404023342	0.408825870
	0.0005900001	0.0006033401	0.634043470	0.640950182
	0.0003761418	0.0003846549	1.000000000	1.000000000
6	0.2899135440	0.0913985858	0.002072996	0.002017516
	0.0857773538	0.0530677646	0.005618615	0.005717930
	0.0430759985	0.0454176815	0.008814475	0.008932544
	0.0268111015	0.0297112246	0.014123284	0.013689336
	0.0120804979	0.0083328239	0.038898611	0.037859089
	0.0044570318	0.0029402391	0.105413246	0.107323764
	0.0022886967	0.0024271663	0.165002618	0.167992921
	0.0014283945	0.0015837736	0.258279159	0.262956270
	0.0009105021	0.0010138106	0.404313558	0.411575258
	0.0005815587	0.0006478026	0.633386303	0.643770832
	0.0003715263	0.0004138615	1.000000000	1.000000000

Iterasi	$\alpha$		$\beta$	
7	0.3338906018	0.0656135983	0.002104443	0.002016997
	0.0948244721	0.0509134979	0.005674413	0.005831910
	0.0431143984	0.0498961549	0.008879940	0.009061678
	0.0265020291	0.0331398172	0.014384174	0.013693086
	0.0131036432	0.0082750645	0.039694652	0.038048237
	0.0048595335	0.0028621239	0.107003110	0.110061966
	0.0022747506	0.0026559099	0.166779871	0.171547072
	0.0014042908	0.0017576086	0.259954170	0.267377458
	0.0008973623	0.0011311611	0.405235989	0.416698096
	0.0005754971	0.0007259642	0.632540254	0.648752473
	0.0003692142	0.0004657819	1.000000000	1.000000000
8	0.3928080794	0.0390502406	0.002163355	0.002018506
	0.1098952876	0.0483972550	0.005785743	0.006049529
	0.0438368787	0.0573345385	0.009015444	0.009303250
	0.0263331010	0.0390262808	0.014905423	0.013736909
	0.0147819018	0.0083012017	0.041218723	0.038466161
	0.0055268116	0.0027701031	0.110178921	0.115399439
	0.0022828208	0.0030262420	0.170310571	0.178378978
	0.0013807330	0.0020495237	0.263268804	0.275723846
	0.0008860967	0.0013327238	0.407085015	0.426112121
	0.0005727135	0.0008626891	0.631076500	0.657456374
	0.0003704673	0.0005581391	1.000000000	1.000000000
9	0.4636649955	0.0175847042	0.002269781	0.002019271
	0.1332674122	0.0452082711	0.005978046	0.006442353
	0.0452996913	0.0686999248	0.009265732	0.009726235
	0.0260299710	0.0485497302	0.015953409	0.013855065
	0.0172196565	0.0084095822	0.044036533	0.039197245
	0.0065373939	0.0026364956	0.115856300	0.125366477
	0.0023056541	0.0035679280	0.176428918	0.190906983
	0.0013390724	0.0025047383	0.268696702	0.290697878
	0.0008639350	0.0016590648	0.409516357	0.442496817
	0.0005659750	0.0010907357	0.627523081	0.671807131
	0.0003715472	0.0007163792	1.000000000	1.000000000



Iterasi	$\alpha$		$\beta$	
10	0.5382883727	0.0054408455	0.002446186	0.002009728
	0.1657793495	0.0409759346	0.006257368	0.007085765
	0.0469744365	0.0840379893	0.009675479	0.010390397
	0.0248792925	0.0624317554	0.017988865	0.014097601
	0.0201223798	0.0085265492	0.048922531	0.040256667
	0.0078650503	0.0024195868	0.124875302	0.142808548
	0.0023045658	0.0042405848	0.185591743	0.212230119
	0.0012393753	0.0031256510	0.275906092	0.315370144
	0.0008015137	0.0021315670	0.410904780	0.468360782
	0.0005359450	0.0014372526	0.619006005	0.692943633
	0.0003602764	0.0009674119	1.000000000	1.000000000

Pada Tabel 4.5 terdapat nilai probabilitas *forward* dan *backward* yang dipakai pada setiap iterasi pelatihan. Kolom iterasi merujuk kepada iterasi yang menggunakan nilai-nilai di kolom  $\alpha$  dan  $\beta$  dalam rangkaian upaya pembaruan parameter model di iterasi tertentu. Kolom  $\alpha$  berisikan sebuah matriks  $\alpha$ . Matriks  $\alpha$  berisikan nilai  $\alpha(Z_n = \text{naik})$  yang mengacu pada probabilitas terjadinya kenaikan kurs rupiah terhadap dolar Amerika Serikat pada bulan ke- $n$  (rentang Oktober 2023 - Agustus 2024) di kolom pertama, dengan baris sebagai indeks pengamatan yang dilakukan ( $n$ ). Selain itu matriks  $\alpha$  juga berisikan nilai  $\alpha(Z_n = \text{turun})$  yang mengacu pada probabilitas terjadinya kenaikan kurs rupiah terhadap dolar Amerika Serikat pada bulan ke- $n$  (rentang Oktober 2023 - Agustus 2024) di kolom ke-2, dengan baris sebagai indeks pengamatan yang dilakukan ( $n$ ). Kolom  $\beta$  berisikan sebuah matriks  $\beta$ . Matriks  $\beta$  berisikan probabilitas terjadinya kondisi inflasi pada bulan ke- $n + 1$  sampai akhir pengamatan (rentang Oktober 2023 - Agustus 2024), jika diketahui pada bulan ke- $n$  kondisi kurs rupiah terhadap dolar Amerika Serikat adalah naik ( $\beta(Z_n = \text{naik})$ ) di kolom pertama. Sedangkan di kolom ke-2 berisikan probabilitas terjadinya kondisi inflasi pada bulan ke- $n + 1$  sampai akhir pengamatan (rentang Oktober 2023 - Agustus 2024), jika diketahui pada bulan ke- $n$  kondisi kurs rupiah terhadap dolar Amerika Serikat adalah turun ( $\beta(Z_n = \text{turun})$ ). Baris pada matriks ini menunjukkan indeks pengamatan pertama (Oktober 2023) sampai terakhir (Agustus 2024). Tabel ini merujuk pada nilai  $\alpha$  dan  $\beta$  yang dihasilkan oleh parameter sebelumnya, sekaligus menjadi dasar untuk membentuk nilai  $\gamma_n(i)$  dan  $\xi_n(i,j)$  sebagai produk ekspektasi untuk kemudian dilanjutkan pada proses pembaruan parameter (maksimasi). Nilai  $\gamma_n(i)$  mengacu pada probabilitas terjadinya kondisi kurs rupiah terhadap dolar Amerika Serikat pada bulan ke- $n$  (rentang Oktober 2023 - Agustus 2024) adalah "i", jika diketahui kondisi inflasi sepanjang pengamatan (rentang Oktober 2023 - Agustus 2024). Nilai  $\xi_i(i,j)$  mengacu pada probabilitas terjadinya kondisi kurs rupiah terhadap dolar Amerika Serikat pada bulan ke- $n$  adalah "i" dan di bulan ke- $n + 1$  adalah "j", jika diketahui kondisi inflasi sepanjang pengamatan (rentang Oktober 2023 - Agustus 2024). Dari Tabel 4.5,

didapatkan nilai probabilitas terjadinya urutan kondisi inflasi di Indonesia sepanjang pengamatan (Oktober 2023 sampai Agustus 2024), diketahui parameter model (*likelihood* model), yang mana ini adalah nilai *likelihood* model dengan parameter yang pertama kali dibangun, yakni sebesar 0.000053. Nilai ini diperoleh dengan menjumlahkan probabilitas kondisi kurs rupiah pada pengamatan terakhir adalah naik ( $\alpha_{11}(naik)$ ) dan turun ( $\alpha_{11}(turun)$ ) yang terdapat di iterasi pertama Tabel 4.5. Dari Tabel 4.5, Persamaan 2.58 digunakan untuk membangun  $\xi_n(i,j)$  dari pengamatan pertama (Oktober 2023) sampai dengan 1 pengamatan sebelum terakhir (Juli 2024) pada setiap iterasi pelatihan. Dari Tabel 4.5 juga diterapkan Persamaan 2.59 untuk membangun  $\gamma_n(i)$  dari pengamatan pertama (Oktober 2023) sampai (Juli 2024) pada setiap iterasi pelatihan. Berikut Tabel 4.6 yang berisi nilai  $\gamma_n(i)$  dan  $\xi_n(i,j)$  yang digunakan pada tiap iterasinya untuk pembaruan parameter model.

**Tabel 4.6** Tabel Hasil  $\xi_n(i,j)$ , dan  $\gamma_n(i)$  Tiap Iterasi Pelatihan

Iterasi	$\xi_n(i,j)$				$\gamma_n(i)$	
	$\xi_n(i,naik)$		$\xi_n(i,turun)$			
1	0.3364	0.2295	0.2207	0.2134	0.5571	0.4429
	0.3207	0.2084	0.2452	0.2257	0.5659	0.4341
	0.3015	0.2276	0.2275	0.2433	0.5291	0.4709
	0.3212	0.2456	0.2080	0.2253	0.5292	0.4708
	0.3422	0.2245	0.2245	0.2087	0.5668	0.4332
	0.3210	0.2078	0.2457	0.2254	0.5667	0.4333
	0.2995	0.2260	0.2293	0.2451	0.5289	0.4711
	0.2977	0.2276	0.2279	0.2468	0.5256	0.4744
	0.2976	0.2278	0.2277	0.2469	0.5253	0.4747
	0.2985	0.2285	0.2269	0.2461	0.5254	0.4746
					0.5270	0.4729
2	0.3497	0.2149	0.2327	0.2028	0.5823	0.4177
	0.3187	0.2079	0.2459	0.2275	0.5646	0.4354
	0.2989	0.2276	0.2277	0.2458	0.5266	0.4734
	0.3178	0.2451	0.2087	0.2284	0.5265	0.4735
	0.3380	0.2249	0.2249	0.2122	0.5629	0.4371
	0.3176	0.2086	0.2453	0.2285	0.5629	0.4371
	0.2969	0.2261	0.2293	0.2477	0.5262	0.4738
	0.2951	0.2276	0.2279	0.2494	0.5230	0.4770
	0.2950	0.2278	0.2277	0.2494	0.5227	0.4773
	0.2956	0.2283	0.2272	0.2488	0.5228	0.4772
					0.5239	0.4760
3	0.3681	0.2002	0.2434	0.1882	0.6116	0.3884
	0.3179	0.2037	0.2504	0.2280	0.5684	0.4316
	0.2938	0.2275	0.2279	0.2508	0.5216	0.4784
	0.3157	0.2486	0.2056	0.2301	0.5213	0.4787
	0.3396	0.2246	0.2246	0.2111	0.5643	0.4357
	0.3154	0.2055	0.2488	0.2303	0.5642	0.4358
	0.2912	0.2259	0.2297	0.2532	0.5209	0.4791
	0.2891	0.2277	0.2280	0.2552	0.5171	0.4829
	0.2890	0.2279	0.2278	0.2553	0.5168	0.4832
	0.2897	0.2285	0.2271	0.2546	0.5169	0.4831
					0.5182	0.4817

Iterasi	$\xi_n(i,j)$				$\gamma_n(i)$	
	$\xi_n(i,naik)$		$\xi_n(i,turun)$			
4	0.3947	0.1825	0.2547	0.1681	0.6494	0.3506
	0.3180	0.1955	0.2592	0.2273	0.5772	0.4228
	0.2855	0.2274	0.2280	0.2591	0.5135	0.4865
	0.3142	0.2560	0.1987	0.2310	0.5129	0.4871
	0.3466	0.2237	0.2237	0.2060	0.5703	0.4297
	0.3139	0.1985	0.2563	0.2313	0.5702	0.4298
	0.2821	0.2252	0.2303	0.2624	0.5124	0.4876
	0.2793	0.2276	0.2280	0.2652	0.5073	0.4927
	0.2791	0.2279	0.2277	0.2653	0.5068	0.4932
	0.2801	0.2287	0.2268	0.2643	0.5070	0.4930
					0.5088	0.4912
5	0.4328	0.1589	0.2671	0.1411	0.6999	0.3001
	0.3185	0.1827	0.2732	0.2255	0.5918	0.4082
	0.2735	0.2269	0.2278	0.2718	0.5013	0.4987
	0.3129	0.2683	0.1875	0.2313	0.5004	0.4996
	0.3594	0.2218	0.2218	0.1970	0.5813	0.4187
	0.3124	0.1872	0.2688	0.2317	0.5812	0.4188
	0.2685	0.2236	0.2310	0.2768	0.4996	0.5004
	0.2646	0.2269	0.2276	0.2809	0.4922	0.5078
	0.2643	0.2274	0.2272	0.2811	0.4915	0.5085
	0.2658	0.2286	0.2259	0.2797	0.4917	0.5083
					0.4944	0.5056
6	0.4861	0.1276	0.2791	0.1072	0.7652	0.2348
	0.3191	0.1644	0.2946	0.2220	0.6136	0.3864
	0.2568	0.2254	0.2267	0.2912	0.4834	0.5166
	0.3112	0.2871	0.1709	0.2308	0.4821	0.5179
	0.3800	0.2182	0.2183	0.1835	0.5983	0.4017
	0.3104	0.1705	0.2878	0.2313	0.5982	0.4018
	0.2495	0.2203	0.2314	0.2989	0.4808	0.5192
	0.2437	0.2250	0.2260	0.3053	0.4697	0.5303
	0.2434	0.2256	0.2253	0.3057	0.4687	0.5313
	0.2454	0.2276	0.2236	0.3034	0.4690	0.5310
					0.4730	0.5270

Iterasi	$\xi_n(i,j)$				$\gamma_n(i)$	
	$\xi_n(i,naik)$		$\xi_n(i,turun)$			
7	0.5554	0.0890	0.2861	0.0695	0.8415	0.1585
	0.3189	0.1397	0.3256	0.2159	0.6444	0.3556
	0.2348	0.2217	0.2237	0.3198	0.4585	0.5415
	0.3084	0.3146	0.1482	0.2289	0.4565	0.5435
	0.4110	0.2117	0.2119	0.1653	0.6229	0.3771
	0.3069	0.1475	0.3158	0.2298	0.6227	0.3773
	0.2239	0.2133	0.2304	0.3324	0.4544	0.5456
	0.2155	0.2200	0.2217	0.3428	0.4372	0.5628
	0.2149	0.2210	0.2206	0.3435	0.4355	0.5645
	0.2179	0.2243	0.2180	0.3398	0.4360	0.5640
					0.4422	0.5578
8	0.6351	0.0495	0.2800	0.0353	0.9151	0.0849
	0.3162	0.1093	0.3684	0.2060	0.6847	0.3153
	0.2086	0.2141	0.2170	0.3603	0.4256	0.5744
	0.3033	0.3528	0.1193	0.2245	0.4227	0.5773
	0.4551	0.2006	0.2010	0.1433	0.6561	0.3439
	0.3005	0.1182	0.3553	0.2261	0.6557	0.3442
	0.1918	0.1996	0.2268	0.3817	0.4187	0.5813
	0.1794	0.2090	0.2120	0.4000	0.3915	0.6085
	0.1785	0.2107	0.2099	0.4009	0.3884	0.6116
	0.1828	0.2161	0.2064	0.3947	0.3892	0.6108
					0.3990	0.6010
9	0.7125	0.0198	0.2549	0.0129	0.9674	0.0326
	0.3091	0.0768	0.4232	0.1910	0.7323	0.2677
	0.1809	0.2008	0.2049	0.4134	0.3858	0.6142
	0.2947	0.4024	0.0871	0.2159	0.3817	0.6183
	0.5128	0.1834	0.1842	0.1196	0.6970	0.3030
	0.2887	0.0852	0.4075	0.2186	0.6962	0.3038
	0.1551	0.1757	0.2189	0.4504	0.3739	0.6261
	0.1372	0.1880	0.1935	0.4813	0.3307	0.6693
	0.1357	0.1908	0.1895	0.4840	0.3252	0.6748
	0.1417	0.1999	0.1848	0.4737	0.3265	0.6735
					0.3415	0.6585

Iterasi	$\xi_n(i,j)$				$\gamma_n(i)$	
	$\xi_n(i,naik)$		$\xi_n(i,turun)$			
10	0.7762	0.0051	0.2156	0.0031	0.9918	0.0082
	0.2946	0.0477	0.4867	0.1710	0.7813	0.2187
	0.1552	0.1819	0.1871	0.4758	0.3423	0.6577
	0.2805	0.4610	0.0566	0.2019	0.3371	0.6629
	0.5790	0.1607	0.1624	0.0978	0.7415	0.2585
	0.2681	0.0540	0.4716	0.2062	0.7397	0.2603
	0.1168	0.1408	0.2054	0.5371	0.3221	0.6779
	0.0935	0.1545	0.1640	0.5879	0.2576	0.7424
	0.0911	0.1587	0.1569	0.5932	0.2481	0.7519
	0.0984	0.1729	0.1514	0.5772	0.2499	0.7501
					0.2714	0.7286

Pada Tabel 4.6 terdapat subkolom  $\xi_n(i,naik)$  dan  $\xi_n(i,turun)$ . Larik pada subkolom  $\xi_n(i,naik)$  menyimpan nilai probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat pada bulan ke- $n$  adalah "i" dan di bulan  $n + 1$  mengalami kenaikan, jika diketahui kondisi inflasi yang terjadi sepanjang observasi (Oktober 2023 sampai Agustus 2024), dengan  $n$  sebagai indeks barisnya sebagai representasi bulan pengamatan yang bertransisi (Oktober 2023 sampai Juli 2024). Larik pada subkolom  $\xi_n(i,turun)$  menyimpan nilai probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat pada bulan ke- $n$  adalah "i" dan di bulan  $n + 1$  mengalami penurunan, jika diketahui kondisi inflasi yang terjadi sepanjang observasi (Oktober 2023 sampai Agustus 2024), dengan  $n$  sebagai indeks barisnya sebagai representasi bulan pengamatan yang kondisi kursnya bertransisi (Oktober 2023 sampai Juli 2024). Pada subkolom  $\xi_n(i,naik)$  serta  $\xi_n(i,turun)$  indeks kolom merujuk pada kondisi kurs rupiah terhadap dolar Amerika Serikat yang terjadi pada bulan ke- $n$ , dengan kolom pertama dan kedua masing-masing menunjukkan kondisi naik dan turun. Selain  $\xi_i(i,j)$ , pada Tabel 4.6 juga terdapat kolom  $\gamma_n(i)$  yang merupakan probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat pada bulan ke- $n$  adalah "i", jika diketahui kondisi inflasi yang terjadi sepanjang pengamatan (Oktober 2023 sampai Agustus 2024). Indeks kolom pada  $\gamma_n(i)$  merujuk pada kondisi kurs rupiah terhadap dolar Amerika Serikat pada bulan ke- $n$ , dengan  $n$  sebagai indeks baris yang merepresentasikan bulan pengamatan, di mana kondisi kurs rupiah terhadap dolar Amerika Serikat yang terjadi adalah "i". Kolom pertama dan kedua masing-masing menunjukkan kondisi naik dan turun.

Pada Tabel 4.6, nilai probabilitas terjadinya kenaikan kurs rupiah terhadap dolar Amerika Serikat, dengan diketahui kondisi inflasi sepanjang Oktober 2023 sampai Agustus 2024 ( $\gamma_1(naik)$ ) selalu mengalami peningkatan, nilai probabilitas terjadinya penurunan kurs rupiah terhadap dolar Amerika Serikat, dengan diketahui kondisi inflasi sepanjang Oktober 2023 sampai Agustus 2024 ( $\gamma_1(turun)$ )

selalu mengalami penurunan sepanjang iterasi pelatihan. Artinya, algoritma Baum-Welch setiap pelatihannya akan meningkatkan probabilitas inisiasi untuk kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik", sebaliknya nilai probabilitas inisiasi untuk kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun" mengalami penurunan.

Pada Tabel 4.6, nilai probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik", bersyarat pada kondisi inflasi selama periode pengamatan meningkat seiring dengan bertambahnya iterasi, terutama pada pengamatan pertama ( $\gamma_1(naik)$ ), ke-2 ( $\gamma_2(naik)$ ), ke-5 ( $\gamma_5(naik)$ ), dan ke-6 ( $\gamma_6(naik)$ ). Selain itu, nilai probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun", bersyarat pada kondisi inflasi selama periode pengamatan meningkat seiring dengan bertambahnya iterasi, terutama pada pengamatan ke-3 ( $\gamma_3(turun)$ ), ke-4 ( $\gamma_4(turun)$ ), ke-7 ( $\gamma_7(turun)$ ), ke-8 ( $\gamma_8(turun)$ ), ke-9 ( $\gamma_9(turun)$ ), ke-10 ( $\gamma_{10}(turun)$ ), dan 11 ( $\gamma_{11}(turun)$ ). Di samping itu, diketahui bahwa saat pengamatan pertama, ke-2, ke-5, dan ke-6 inflasi di Indonesia sedang mengalami kenaikan, sedangkan untuk pengamatan ke-3, ke-4, ke-7, ke-8, ke-9, ke-10, dan ke-11 kondisi inflasi di Indonesia sedang mengalami penurunan. Dari sini dapat dilihat bahwa algoritma Baum-Welch cenderung untuk menjadikan kondisi inflasi di Indonesia memiliki kondisi yang sama dengan kurs rupiah terhadap dolar Amerika Serikat (keduanya naik atau keduanya turun) pada waktu pengamatan yang sama. Hal ini mengisyaratkan bahwa sepanjang iterasi pelatihan oleh algoritma Baum-Welch, nilai probabilitas emisi akan meningkat, khususnya untuk emisi di mana kurs dan inflasi saling mengalami kenaikan atau penurunan.

Pada Tabel 4.6, probabilitas transisi kurs rupiah terhadap dolar Amerika Serikat dari keadaan naik ke naik, dengan diketahui kondisi inflasi di Indonesia sepanjang pengamatan ( $\xi_n(naik,naik)$ ), jika nilainya dijumlahkan dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 ( $n = 1$ ) sampai sebelum akhir pengamatan ( $n = 10$ ) di bulan Juli 2024, maka nilainya cenderung menurun seiring bertambahnya iterasi pelatihan. Hal ini juga terjadi pada probabilitas transisi kurs rupiah terhadap dolar Amerika Serikat dari keadaan turun ke naik, dengan diketahui kondisi inflasi di Indonesia sepanjang pengamatan ( $\xi_n(turun,naik)$ ). Sementara itu, probabilitas transisi kurs rupiah terhadap dolar Amerika Serikat dari keadaan naik ke turun, dengan diketahui kondisi inflasi di Indonesia sepanjang pengamatan ( $\xi_n(naik,turun)$ ), jika nilainya dijumlahkan dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum akhir pengamatan ( $n = 10$ ) di bulan Agustus 2024, maka nilainya cenderung meningkat seiring bertambahnya iterasi pelatihan. Hal ini juga terjadi pada probabilitas transisi kurs rupiah terhadap dolar Amerika Serikat dari keadaan turun ke turun, dengan diketahui kondisi inflasi di Indonesia sepanjang pengamatan ( $\xi_n(turun,turun)$ ), jika nilainya dijumlahkan dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum akhir pengamatan ( $n = 10$ ) di bulan Agustus 2024, maka nilainya cenderung meningkat seiring bertambahnya iterasi pelatihan. Fenomena ini menunjukkan bahwa algoritma Baum-Welch cenderung untuk memperbarui probabilitas transisi kondisi kurs rupiah terhadap dolar Amerika Serikat untuk berpindah dari keadaan "naik" ke "turun", sementara mencegah keadaan "turun" berpindah ke "naik" dalam setiap

transisi. Setelah  $\gamma_n(i)$  dan  $\xi_n(i,j)$  didapatkan untuk setiap kondisi kurs rupiah terhadap dolar Amerika Serikat dan sepanjang observasi yang terjadi, maka ketiga parameter model akan diperbarui.

#### 1. Probabilitas Transisi

Algoritma Baum-Welch melakukan pembaharuan pada probabilitas transisi kondisi kurs rupiah terhadap dolar Amerika Serikat yang disimpan pada matriks  $A$ . Probabilitas transisi diperbarui menggunakan Persamaan 2.61. Probabilitas transisi kondisi kurs rupiah terhadap dolar Amerika Serikat dari naik ke naik akan diperbarui menggunakan penjumlahan probabilitas  $\xi_n(naik,naik)$  dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum pengamatan terakhir ( $n = 10$ ) di bulan Juli 2024, kemudian hasilnya dibagi dengan hasil penjumlahan probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik", bersyarat pada kondisi inflasi selama periode pengamatan ( $\gamma_n(naik)$ ) dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum pengamatan terakhir ( $n = 10$ ) di bulan Juli 2024. Probabilitas transisi kondisi kurs rupiah terhadap dolar Amerika Serikat dari naik ke turun akan diperbarui menggunakan penjumlahan probabilitas  $\xi_n(naik,turun)$  dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum pengamatan terakhir ( $n = 10$ ) di bulan Juli 2024, kemudian hasilnya dibagi dengan hasil penjumlahan probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik", bersyarat pada kondisi inflasi selama periode pengamatan ( $\gamma_n(naik)$ ) dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum pengamatan terakhir ( $n = 10$ ) di bulan Juli 2024. Probabilitas transisi kondisi kurs rupiah terhadap dolar Amerika Serikat dari turun ke naik akan diperbarui menggunakan penjumlahan probabilitas  $\xi_n(turun,naik)$  dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum pengamatan terakhir ( $n = 10$ ) di bulan Juli 2024, kemudian hasilnya dibagi dengan hasil penjumlahan probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun", bersyarat pada kondisi inflasi selama periode pengamatan ( $\gamma_n(turun)$ ) dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum pengamatan terakhir ( $n = 10$ ) di bulan Juli 2024. Probabilitas transisi kondisi kurs rupiah terhadap dolar Amerika Serikat dari turun ke turun akan diperbarui menggunakan penjumlahan probabilitas  $\xi_n(turun,turun)$  dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum pengamatan terakhir ( $n = 10$ ) di bulan Juli 2024, kemudian hasilnya dibagi dengan hasil penjumlahan probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun", bersyarat pada kondisi inflasi selama periode pengamatan ( $\gamma_n(turun)$ ) dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai sebelum pengamatan terakhir ( $n = 10$ ) di bulan Juli 2024. Berikut adalah matriks probabilitas transisi kurs rupiah terhadap dolar Amerika Serikat yang diperbarui, yang mana setiap entrinya disesuaikan dengan Persamaan 2.61 untuk pembaruan transisi kondisi kurs rupiah terhadap dolar Amerika Serikat.



$$\mathbf{A}^* = \begin{bmatrix} \frac{\sum_{n=1}^{N-1} \xi_n(naik,naik)}{\sum_{n=1}^{N-1} \gamma_n(naik)} & \frac{\sum_{n=1}^{N-1} \xi_n(naik,turun)}{\sum_{n=1}^{N-1} \gamma_n(naik)} \\ \frac{\sum_{n=1}^{N-1} \xi_n(turun,naik)}{\sum_{n=1}^{N-1} \gamma_n(turun)} & \frac{\sum_{n=1}^{N-1} \xi_n(turun,turun)}{\sum_{n=1}^{N-1} \gamma_n(turun)} \end{bmatrix}$$

Entri  $A_{11}^*$  menyimpan nilai pembaharuan dari probabilitas kurs rupiah terhadap dolar Amerika Serikat mengalami kenaikan, jika diketahui tepat satu waktu sebelumnya juga mengalami kenaikan. Entri  $A_{12}^*$  menyimpan nilai pembaharuan dari probabilitas kurs rupiah terhadap dolar Amerika Serikat mengalami penurunan, jika diketahui tepat satu waktu sebelumnya mengalami kenaikan. Entri  $A_{21}^*$  menyimpan nilai pembaharuan dari probabilitas kurs rupiah terhadap dolar Amerika Serikat mengalami kenaikan, jika diketahui tepat satu waktu sebelumnya mengalami penurunan. Entri  $A_{22}^*$  menyimpan nilai pembaharuan dari probabilitas kurs rupiah terhadap dolar Amerika Serikat mengalami penurunan, jika diketahui tepat satu waktu sebelumnya juga mengalami penurunan.

## 2. Probabilitas Emisi

Algoritma Baum-Welch melakukan pembaharuan pada probabilitas emisi yang disimpan pada matriks  $B$ . Probabilitas emisi diperbarui menggunakan Persamaan 2.62.

Probabilitas emisi kondisi kurs rupiah terhadap dolar Amerika Serikat mengalami kenaikan dan kondisi inflasi di Indonesia juga mengalami kenaikan diperbarui dengan menjumlahkan beberapa probabilitas kondisi kurs rupiah terhadap dolar AS adalah "naik", bersyarat pada inflasi selama periode pengamatan ( $\gamma_n(naik)$ ) dari awal pengamatan di bulan Oktober 2023 sampai akhir pengamatan ( $n = 11$ ) di bulan Agustus 2024, di mana kondisi inflasi di Indonesia pada pengamatan ke- $n$  adalah naik, kemudian dibagi dengan hasil penjumlahan probabilitas kondisi kurs rupiah terhadap dolar AS adalah "naik", bersyarat pada inflasi selama periode pengamatan ( $\gamma_n(naik)$ ) dari awal ( $n = 1$ ) di bulan Oktober 2023 sampai akhir pengamatan ( $n = 11$ ) di bulan Agustus 2024.

Probabilitas emisi kondisi kurs rupiah terhadap dolar Amerika Serikat mengalami kenaikan dan kondisi inflasi di Indonesia mengalami penurunan diperbarui dengan menjumlahkan beberapa probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik", bersyarat pada inflasi selama periode pengamatan ( $\gamma_n(naik)$ ) dari awal pengamatan di bulan Oktober 2023 sampai akhir pengamatan ( $n = 11$ ) di bulan Agustus 2024, di mana kondisi inflasi di Indonesia pada pengamatan ke- $n$  adalah "turun", kemudian dibagi dengan hasil penjumlahan probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik", bersyarat pada inflasi selama periode pengamatan ( $\gamma_n(naik)$ ) dari awal ( $n = 1$ ) di bulan Oktober 2023 sampai akhir pengamatan ( $n = 11$ ) di bulan Agustus 2024.

Probabilitas emisi kondisi kurs rupiah terhadap dolar Amerika Serikat mengalami penurunan dan kondisi inflasi di Indonesia mengalami kenaikan diperbarui dengan menjumlahkan beberapa probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun", bersyarat pada inflasi selama

periode pengamatan ( $\gamma_n(turun)$ ) dari awal pengamatan di bulan Oktober 2023 sampai akhir pengamatan ( $n = 11$ ) di bulan Agustus 2024, di mana kondisi inflasi di Indonesia pada pengamatan ke- $n$  adalah "naik", kemudian dibagi dengan hasil penjumlahan probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun", bersyarat pada inflasi selama periode pengamatan ( $\gamma_n(turun)$ ) dari awal ( $n = 1$ ) di bulan Oktober 2023 sampai akhir pengamatan ( $n = 11$ ) di bulan Agustus 2024.

Probabilitas emisi kondisi kurs rupiah terhadap dolar Amerika Serikat mengalami penurunan dan kondisi inflasi di Indonesia juga mengalami penurunan diperbarui dengan menjumlahkan beberapa probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun", bersyarat pada inflasi selama periode pengamatan ( $\gamma_n(turun)$ ) dari awal pengamatan di bulan Oktober 2023 sampai akhir pengamatan ( $n = 11$ ) di bulan Agustus 2024, di mana kondisi inflasi di Indonesia pada pengamatan ke- $n$  adalah "turun", kemudian dibagi dengan hasil penjumlahan probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun", bersyarat pada inflasi selama periode pengamatan ( $\gamma_n(turun)$ ) dari awal ( $n = 1$ ) di bulan Oktober 2023 sampai akhir pengamatan ( $n = 11$ ) di bulan Agustus 2024. Probabilitas emisi terbaru disimpan dalam sebuah matriks yang dinamai matriks  $B^*$  dengan ukuran yang sama dengan matriks  $B$ . Berikut adalah matriks  $B^*$  yang setiap entrinya merupakan bentuk pembaruan probabilitas emisi untuk setiap kemungkinan emisi menggunakan Persamaan 2.62.

$$B^* = \begin{bmatrix} \frac{\sum_{n=1}^N \gamma_n(naik)I(X_n, M_{naik})}{\sum_{n=1}^N \gamma_n(naik)} & \frac{\sum_{n=1}^N \gamma_n(naik)I(X_n, M_{turun})}{\sum_{n=1}^N \gamma_n(naik)} \\ \frac{\sum_{n=1}^N \gamma_n(turun)I(X_n, M_{naik})}{\sum_{n=1}^N \gamma_n(turun)} & \frac{\sum_{n=1}^N \gamma_n(turun)I(X_n, M_{turun})}{\sum_{n=1}^N \gamma_n(turun)} \end{bmatrix}$$

Entri  $B_{11}^*$  menyimpan nilai pembaharuan dari probabilitas inflasi di Indonesia sedang mengalami kenaikan, diketahui kurs rupiah terhadap dolar Amerika Serikat juga sedang mengalami kenaikan. Entri  $B_{12}^*$  menyimpan nilai pembaharuan dari probabilitas nilai inflasi di Indonesia sedang mengalami penurunan, diketahui kurs rupiah terhadap dolar Amerika Serikat sedang mengalami kenaikan. Entri  $B_{21}^*$  menyimpan nilai pembaharuan dari probabilitas inflasi di Indonesia sedang mengalami kenaikan, diketahui kurs rupiah terhadap dolar Amerika Serikat sedang mengalami penurunan. Entri  $B_{22}^*$  menyimpan nilai pembaharuan dari probabilitas inflasi di Indonesia sedang mengalami penurunan, diketahui kurs rupiah terhadap dolar Amerika Serikat juga sedang mengalami penurunan.

### 3. Probabilitas Inisiasi

Terakhir, algoritma Baum-Welch juga memperbaharui probabilitas inisiasi untuk setiap kondisi kurs rupiah terhadap dolar Amerika Serikat.

Probabilitas emisi terbaru diperoleh dengan menggunakan Persamaan 2.60. Probabilitas inisiasi terbaru kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik" diperbarui dengan nilai probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik", bersyarat pada inflasi selama periode pengamatan ( $\gamma_1(naik)$ ). Di sisi lain, probabilitas emisi terbaru diperoleh dengan menggunakan Persamaan 2.60. Probabilitas inisiasi terbaru kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun" diperbarui dengan nilai probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun", bersyarat pada inflasi selama periode pengamatan ( $\gamma_1(turun)$ ). Nilai probabilitas inisiasi terbaru disimpan dalam vektor  $\pi^*$ .

$$\pi^* = \begin{bmatrix} \end{bmatrix}$$

Nilai di entri pertama dan kedua, masing-masing merujuk pada hasil pembaharuan probabilitas inisiasi terjadinya kondisi naik dan turun terhadap kondisi kurs rupiah terhadap dolar Amerika Serikat di fase inisiasi.

Penyesuaian yang dilakukan terhadap entri-entri matriks  $A^*$ ,  $B^*$ , dan  $\pi^*$  dengan Persamaan 2.61, 2.62, dan 2.60 menginstruksikan substitusi nilai probabilitas transisi kondisi kurs rupiah terhadap dolar Amerika Serikat dari bulan ke- $n$  adalah "i" dan bulan ke- $n + 1$  adalah "j", jika diketahui kondisi inflasi sepanjang pengamatan ( $\xi_n(i, j)$ ) dan probabilitas kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "i", jika diketahui kondisi inflasi sepanjang pengamatan ( $\gamma_n(i)$ ) yang terdapat pada Tabel 4.6. Dari substitusi nilai-nilai tersebut, didapatkan probabilitas inisiasi, emisi, dan transisi yang telah diperbarui untuk setiap iterasinya. Pembaruan ini tentunya juga memberikan perubahan terhadap probabilitas terjadinya kondisi inflasi sepanjang pengamatan, jika diketahui parameter model (*likelihood* model) sepanjang iterasi yang dilakukan.

Kondisi inflasi yang terjadi pada rentang pengamatan (Oktober 2023 sampai Agustus 2024) adalah Naik, Naik, Turun, Turun, Naik, Naik, Turun, Turun, Turun, Turun, Turun. Untuk menghitung *likelihood* dari barisan observasi ini, maka digunakan Persamaan 2.57. Nilai *likelihood* diperoleh dengan menjumlahkan probabilitas *forward* tepat di pengamatan terakhir ( $n = 11$ ) untuk setiap kondisi kurs rupiah terhadap dolar Amerika Serikat, yaitu probabilitas terjadinya kenaikan kurs rupiah terhadap dolar Amerika Serikat pada pengamatan terakhir (Agustus 2024) ( $\alpha(Z_{11} = Naik)$ ) dan probabilitas terjadinya penurunan kurs rupiah terhadap dolar Amerika Serikat pada pengamatan terakhir (Agustus 2024) ( $\alpha(Z_{11} = Turun)$ ). Perhitungan *likelihood* menggunakan parameter model sebelum dan sesudah pelatihan oleh algoritma Baum-Welch pada iterasi pertama sampai terkahir (10). Perubahan *likelihood* ini tentunya diakibatkan oleh perubahan nilai  $\xi$  dan  $\gamma$  sebagai pembentuk pembaruan parameter model sepanjang iterasi pelatihan.

Tabel 4.6 memberikan gambaran bagaimana kecenderungan algoritma Baum-Welch melakukan fase maksimasi (pembaruan parameter model). Hal ini dikarenakan nilai-nilai tersebut berperan langsung dalam proses maksimasi

(pembaruan parameter model) di setiap iterasi pelatihan. Berikut nilai probabilitas inisiasi, emisi, transisi, serta *likelihood* model yang didapatkan dari hasil pembaruan sepanjang iterasi pelatihan seperti di Tabel 4.7 berikut.

**Tabel 4.7** Hasil Pembaruan Parameter Model Sepanjang Iterasi Pelatihan

Iterasi	Prob. Inisiasi	Prob. Emisi	Prob. Transisi	<i>Likelihood</i>
1	$\begin{bmatrix} 0.5571 & 0.4429 \end{bmatrix}$	$\begin{bmatrix} 0.3794 & 0.6206 \\ 0.3450 & 0.6550 \end{bmatrix}$	$\begin{bmatrix} 0.5787 & 0.4213 \\ 0.4920 & 0.5080 \end{bmatrix}$	0.0007405722
2	$\begin{bmatrix} 0.5823 & 0.4177 \end{bmatrix}$	$\begin{bmatrix} 0.3823 & 0.6177 \\ 0.3417 & 0.6583 \end{bmatrix}$	$\begin{bmatrix} 0.5762 & 0.4238 \\ 0.4889 & 0.5111 \end{bmatrix}$	0.0007434484
3	$\begin{bmatrix} 0.6116 & 0.3884 \end{bmatrix}$	$\begin{bmatrix} 0.3885 & 0.6115 \\ 0.3344 & 0.6656 \end{bmatrix}$	$\begin{bmatrix} 0.5734 & 0.4266 \\ 0.4851 & 0.5149 \end{bmatrix}$	0.0007490372
4	$\begin{bmatrix} 0.6494 & 0.3506 \end{bmatrix}$	$\begin{bmatrix} 0.3988 & 0.6012 \\ 0.3224 & 0.6776 \end{bmatrix}$	$\begin{bmatrix} 0.5700 & 0.4300 \\ 0.4795 & 0.5205 \end{bmatrix}$	0.0007607967
5	$\begin{bmatrix} 0.6999 & 0.3001 \end{bmatrix}$	$\begin{bmatrix} 0.4142 & 0.5858 \\ 0.3046 & 0.6954 \end{bmatrix}$	$\begin{bmatrix} 0.5658 & 0.4342 \\ 0.4711 & 0.5289 \end{bmatrix}$	0.0007853877
6	$\begin{bmatrix} 0.7652 & 0.2348 \end{bmatrix}$	$\begin{bmatrix} 0.4363 & 0.5637 \\ 0.2795 & 0.7205 \end{bmatrix}$	$\begin{bmatrix} 0.5609 & 0.4391 \\ 0.4576 & 0.5424 \end{bmatrix}$	0.0008349962
7	$\begin{bmatrix} 0.8415 & 0.1585 \end{bmatrix}$	$\begin{bmatrix} 0.4668 & 0.5332 \\ 0.2464 & 0.7536 \end{bmatrix}$	$\begin{bmatrix} 0.5560 & 0.4440 \\ 0.4363 & 0.5637 \end{bmatrix}$	0.0009286065
8	$\begin{bmatrix} 0.9151 & 0.0849 \end{bmatrix}$	$\begin{bmatrix} 0.5067 & 0.4933 \\ 0.2072 & 0.7928 \end{bmatrix}$	$\begin{bmatrix} 0.5519 & 0.4481 \\ 0.4041 & 0.5959 \end{bmatrix}$	0.0010879260
9	$\begin{bmatrix} 0.9674 & 0.0326 \end{bmatrix}$	$\begin{bmatrix} 0.5565 & 0.4435 \\ 0.1667 & 0.8333 \end{bmatrix}$	$\begin{bmatrix} 0.5498 & 0.4502 \\ 0.3601 & 0.6399 \end{bmatrix}$	0.0013276880
10	$\begin{bmatrix} 0.9918 & 0.0082 \end{bmatrix}$	$\begin{bmatrix} 0.6160 & 0.3840 \\ 0.1304 & 0.8696 \end{bmatrix}$	$\begin{bmatrix} 0.5495 & 0.4505 \\ 0.3082 & 0.6918 \end{bmatrix}$	0.0016518230

Pada tabel 4.7 terlihat bahwa adanya perubahan terhadap setiap nilai probabilitas inisiasi, transisi, dan emisi setiap kali melakukan iterasi di samping adanya kenaikan *likelihood*. Nilai probabilitas inisiasi kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik" terus mengalami kenaikan. Di sisi lain, nilai probabilitas inisiasikondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun" terus mengalami penurunan sepanjang proses iterasi pelatihan. Artinya, model sepanjang pelatihan semakin mengukuhkan bahwa pada inisiasi akan terjadi kenaikan pada kurs rupiah terhadap dolar Amerika Serikat. Sebaliknya, model sepanjang pelatihan semakin mengabaikan bahwa pada inisiasi akan terjadi penurunan pada kurs rupiah terhadap dolar Amerika Serikat. Nilai pada matriks probabilitas emisi mengalami kenaikan di setiap diagonalnya, sedangkan nilai komplementer mereka (antidiagonal) sepanjang proses iterasi pelatihan. Artinya, model sepanjang pelatihan semakin mengukuhkan bahwa adanya kesamaan antara kondisi kurs rupiah terhadap dolar Amerika Serikat dengan inflasi di Indonesia (keduanya turun atau keduanya mengalami kenaikan). Sebaliknya, model sepanjang pelatihan semakin mempersempit kemungkinan terjadinya perbedaan kondisi kurs rupiah terhadap dolar Amerika Serikat dengan inflasi di Indonesia. Nilai pada matriks probabilitas transisi mengalami kenaikan di kolom 2, sedangkan nilai di kolom 1 terus menurun sepanjang proses iterasi pelatihan. Artinya, model sepanjang pelatihan semakin mengukuhkan bahwa transisi kondisi kurs rupiah terhadap dolar Amerika Serikat "naik" ke "turun", dan kurs rupiah terhadap dolar Amerika Serikat akan cenderung bertahan di kondisi "turun". Sebaliknya, nilai di kolom 1 yang mengalami penurunan mengartikan bahwa model mempersempit terjadinya kemungkinan perpindahan kondisi kurs rupiah terhadap dolar Amerika Serikat dari "turun" ke "naik" dan juga bertahannya kurs rupiah terhadap dolar Amerika Serikat di kondisi "naik". Perubahan ini tentunya memberikan dampak pada nilai *likelihood* model yang semakin meningkat sepanjang iterasi pelatihan. Didapati bahwa fenomena kecenderungan penurunan atau kenaikan nilai-nilai probabilitas pada Tabel 4.7 serupa dengan yang terjadi pada nilai-nilai probabilitas pada Tabel 4.6. Hal ini terjadi dikarenakan nilai-nilai probabilitas di Tabel 4.7 dibangun dari Tabel 4.6. Pada kasus ini, model yang memiliki *likelihood* lebih tinggi parameternya cenderung untuk menginisiasi kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik", menjadikan jenis kondisi kurs rupiah terhadap dolar Amerika Serikat memiliki kondisi yang sama dengan inflasi di Indonesia (keduanya naik atau keduanya turun), mempermudah transisi kondisi kurs rupiah terhadap dolar Amerika Serikat dari "naik" ke "turun", dan mempersulit transisi kurs rupiah terhadap dolar Amerika Serikat meninggalkan kondisi "turun". Dengan kata lain, probabilitas terjadinya urutan kondisi inflasi di Indonesia seperti pengamatan yang terjadi di bulan Oktober 2023 sampai Agustus 2024, dengan diketahui parameter model (*likelihood*) berbanding lurus dengan banyak iterasi, probabilitas kurs rupiah terhadap dolar Amerika Serikat mengalami kenaikan pada inisiasi, probabilitas transisi kurs rupiah terhadap dolar Amerika Serikat dari kondisi "naik" ke "turun" dan "turun" ke "turun", probabilitas emisi kondisi kurs rupiah terhadap dolar Amerika Serikat ke kondisi inflasi di Indonesia yang mengalami kesamaan (keduanya turun atau naik). Sebaliknya, nilai *likelihood* yang dihasilkan

berbanding terbalik dengan probabilitas kurs rupiah terhadap dolar Amerika Serikat mengalami penurunan pada inisiasi, probabilitas transisi kurs rupiah terhadap dolar Amerika Serikat dari kondisi "turun" ke "naik" dan "naik" ke "naik", probabilitas emisi kondisi kurs rupiah terhadap dolar Amerika Serikat ke kondisi inflasi di Indonesia yang mengalami perbedaan (bertolak belakang kondisinya).

Himpunan parameter yang sudah menyelesaikan keseluruhan iterasi pelatihan nantinya akan dibandingkan dengan himpunan parameter yang dilatih. Perbandingan ini mencakup ketepatan prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat, prediksi nilai kurs rupiah terhadap dolar Amerika Serikat, dan tentunya *likelihood* yang mereka hasilkan.

#### 4.2 Prediksi Urutan Kondisi Kurs Rupiah Terhadap Dolar Amerika Serikat

Parameter yang terlatih dan yang belum dilatih keduanya digunakan untuk memprediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat sebagai *state* tersembunyi. Hasil prediksi urutan dihasilkan adalah yang memaksimalkan nilai probabilitas model di Persamaan 2.27. Urutan kondisi kurs rupiah terhadap dolar Amerika Serikat di sini prediksinya dibantu oleh algoritma Viterbi untuk kepentingan meringankan beban komputasi. Algoritma ini melibatkan  $\delta_n(i)$  selaku nilai probabilitas maksimum dari semua kemungkinan urutan kondisi kurs rupiah terhadap dolar Amerika Serikat yang terjadi dari awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sampai bulan ke- $n$ , dengan diketahui pada bulan ke- $n$  kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "i". Algoritma ini juga melibatkan  $\psi_n(i)$  untuk menyimpan indeks kondisi kurs rupiah terhadap dolar Amerika Serikat yang menuju ke kondisi "i" pada pengamatan ke- $n$ , dengan indeks "0", "1", dan "2" mengacu pada belum bertransisi, naik, dan turun.

Dimulai dari fase inisiasi, dicari  $\delta_1(\text{naik})$  dan  $\delta_1(\text{turun})$  dengan Persamaan 2.31, kemudian memberikan nilai 0 untuk  $\psi_1(\text{naik})$  dan  $\psi_1(\text{turun})$  sesuai Persamaan 2.32. Selanjutnya, pada fase rekursi, nilai  $\delta_2(j)$  sampai  $\delta_{11}(j)$  akan dicari untuk setiap kondisi kurs rupiah terhadap dolar Amerika Serikat sesuai Persamaan 2.33. Selama proses ini, nilai  $\psi_n(j)$  juga dicari sepanjang  $n = 2$  sampai akhir pengamatan ( $n = 11$ ) untuk setiap kondisi kurs rupiah terhadap dolar Amerika Serikat sesuai Persamaan 2.33. Setelah fase rekursi selesai, maka selanjutnya dicari nilai  $P^*$  dan  $Q^*$  sesuai Persamaan 2.35 dan 2.36 untuk menentukan kondisi kurs rupiah terhadap dolar Amerika Serikat apa yang terjadi di akhir pengamatan (naik atau turun). Terakhir, algoritma Viterbi akan melakukan pelacakan/*backtracking* kondisi kurs rupiah terhadap dolar Amerika Serikat yang terjadi pada sebelum akhir pengamatan ( $n = 10$ ) di bulan Juli 2024 sampai awal pengamatan ( $n = 1$ ) di bulan Oktober 2023 sesuai Persamaan 2.37. Hasil dari fase inisiasi, rekursi, dan pelacakan dari algoritma Viterbi berdasar dari matriks  $\delta$  dan  $\psi$ . Berikut Tabel 4.5 ( $\delta$ ) yang berisi probabilitas maksimum dari probabilitas jalur paling memungkinkan sepanjang pengamatan yang diakhiri setiap *state* tersembunyi di sepanjang pengamatan menggunakan parameter model yang belum dilatih.

**Tabel 4.8** Nilai  $\delta$  Sebelum Pelatihan

$t$	$\delta_{naik}$	$\delta_{turun}$
1	0.267857	0.214286
2	0.078510	0.051156
3	0.023011	0.017493
4	0.006745	0.005127
5	0.001977	0.001288
6	0.000579	0.000378
7	0.000170	0.000129
8	0.000050	0.000038
9	0.000015	0.000011
10	0.000004	0.000003
11	0.000001	0.0000009

Pada Tabel 4.8 berisi larik yang menyimpan nilai  $\delta_n(j)$  di setiap entrinya. Kolom pertama larik ini merujuk pada nilai probabilitas maksimum yang dihasilkan dari seluruh kemungkinan urutan kondisi kurs rupiah terhadap dolar Amerika Serikat yang diakhiri oleh keadaan "naik" pada waktu ke- $n$ , dengan indeks barisnya adalah  $n$  sebagai waktu pengamatan. Pada Tabel 4.8 juga terdapat larik yang menyimpan nilai  $\delta_n(j)$  di setiap entrinya. Kolom kedua larik ini merujuk pada nilai probabilitas maksimum yang dihasilkan dari seluruh kemungkinan urutan kondisi kurs rupiah terhadap dolar Amerika Serikat yang diakhiri oleh keadaan "turun" pada waktu ke- $n$ , dengan indeks barisnya adalah  $n$  sebagai waktu pengamatan. Nilai-nilai yang berada di Tabel 4.8 berasal dari penggunaan Persamaan 2.31 dan 2.33 terhadap parameter model. Pada baris terakhir Tabel 4.8 diterapkan Persamaan 2.35 dan 2.36 untuk kepentingan *backtracking*/pelacakan sekaligus penentu kondisi kurs rupiah terhadap dolar Amerika Serikat yang paling mungkin muncul di akhir pengamatan. Namun, sebelum itu Persamaan 2.32 dan 2.34 akan diterapkan atas Tabel 4.5 untuk menghasilkan Tabel  $\psi$  layaknya Tabel 4.9 berikut.

**Tabel 4.9** Nilai  $\psi$  Sebelum Pelatihan

Pengamatan	$\psi_{naik}$	$\psi_{turun}$
1	0	0
2	1	1
3	1	1
4	1	1
5	1	1
6	1	1
7	1	1
8	1	1
9	1	1
10	1	1
11	1	1



Tabel 4.6 ( $\psi$ ) yang berisikan indeks dari *state* tersembunyi sebelumnya yang memaksimalkan nilai probabilitas yang di simpan di Tabel 4.5 ( $\delta$ ). Dengan "1" merujuk kepada *state* naik dan "0" mengartikan belum ada *state* (inisiasi awal). Tabel ini memiliki sebuah larik yang berisikan 11 baris dan 2 kolom. Kolom pertama merujuk pada *state* tersembunyi yang akan memaksimumkan probabilitas  $\delta_n(naik)$ , yang mana *state* tersembunyi ini terjadi pada waktu sebelum  $\delta_n(naik)$  ( $n - 1$ ), dengan  $n$  adalah waktu pengamatan sekaligus menjadi baris bagi larik ini. Kolom pertama merujuk pada *state* tersembunyi yang akan memaksimumkan probabilitas  $\delta_n(turun)$ , yang mana *state* tersembunyi ini terjadi pada waktu sebelum  $\delta_n(turun)$  ( $n - 1$ ), dengan  $n$  adalah waktu pengamatan sekaligus menjadi baris bagi larik ini. Nilai "0" merujuk pada tidak adanya indeks, karena sebelum pengamatan ke-1 ( $n = 1$ ) dilakukan inisiasi daripada inisiasi. Nilai "1" merujuk pada indeks *state* tersembunyi "naik", sedangkan nilai "2" merujuk pada indeks *state* tersembunyi "turun".

Di sisi lain, algoritma Viterbi juga menggunakan parameter yang dilatih untuk memberikan prediksi urutan *state* tersembunyi. Berikut Tabel 4.7 ( $\delta$ ) yang berisi probabilitas maksimum setiap *state* tersembunyi di sepanjang pengamatan menggunakan parameter model yang sudah menyelesaikan seluruh iterasi pelatihan.

**Tabel 4.10** Nilai  $\delta$  Sesudah Menyelesaikan Pelatihan

$t$	$\delta_{naik}$	$\delta_{turun}$
1	0.330016	0.060557
2	0.111707	0.019393
3	0.023568	0.043763
4	0.005178	0.026328
5	0.004998	0.002376
6	0.001692	0.000294
7	0.000357	0.000663
8	0.000078	0.000399
9	0.000047	0.000240
10	0.000028	0.000144
11	0.000017	0.000087

Berikut adalah Tabel 4.8 ( $\psi$ ) yang berisikan *state* tersembunyi sebelumnya yang memaksimalkan nilai probabilitas yang di simpan di Tabel 4.7. Dengan "1" merujuk kepada *state* naik, "0" mengartikan belum ada *state* (inisiasi awal), dan "2" merujuk kepada *state* turun.

**Tabel 4.11** Nilai  $\psi$  Sesudah Menyelesaikan Pelatihan

$t$	$\psi_{naik}$	$\psi_{turun}$
1	0	0
2	1	1
3	1	1
4	2	2
5	2	2
6	1	1
7	1	1
8	2	2
9	2	2
10	2	2
11	2	2

Pada tabel nilai  $\psi$  dan  $\delta$  yang dihasilkan algoritma Viterbi saat menggunakan parameter sebelum pelatihan dan sesudah menyelesaikan pelatihan terdapat perbedaan. Pada Tabel 4.8 nilai  $\delta$  di kolom pertama selalu lebih besar dari kolom ke kedua sepanjang pengamatan. Artinya, nilai probabilitas yang maksimal dari seluruh kemungkinan urutan pengamatan yang berakhir kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik" lebih tinggi dibanding "turun" di sepanjang pengamatan ( $n = 1, n = 2, n = 3, \dots, n = 11$ ) dari bulan Oktober 2023 sampai Agustus 2024. Hal ini tentunya memberikan dampak pada nilai  $\psi$  di Tabel 4.9. Oleh karena itu, pada Tabel 4.9 dimulai dari baris ke-2 sampai akhir nilainya adalah "1" baik pada kolom pertama maupun kedua. Artinya, *state* tersembunyi yang paling mungkin terjadi di sebelum pengamatan ke-2 sampai sebelum pengamatan terakhir adalah "1" (naik). Konsistensi pada kolom pertama dan kedua di Tabel 4.9 (dari baris ke-2) yang selalu menunjukkan nilai "1" mengindikasikan bahwa kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "naik" mendominasi hasil prediksi oleh algoritma Viterbi. Berbeda halnya dengan nilai  $\delta$  dan  $\psi$  yang dihasilkan oleh algoritma Viterbi saat menggunakan parameter yang didapat dari hasil pelatihan. Pada Tabel 4.10, nilai pada kolom kedua seringkali nilainya lebih besar dibanding kolom pertama. Artinya, nilai probabilitas yang maksimal dari seluruh kemungkinan urutan pengamatan yang berakhir pada kondisi kurs rupiah terhadap dolar Amerika Serikat adalah "turun" lebih tinggi dibanding "naik" khususnya di pengamatan ke-3, ke-4, serta ke-7 sampai pengamatan terakhir. Variasi keunggulan nilai probabilitas  $\delta$  yang ditunjukkan di Tabel 4.10 tentunya juga akan memberikan dampak yang selaras terhadap nilai  $\psi$  pada Tabel 4.11. Unggulnya nilai probabilitas seluruh kemungkinan urutan kondisi kurs rupiah terhadap dolar Amerika Serikat yang diakhiri terjadinya penurunan pada pengamatan ke-3 ( $\delta_3(turun)$ ), ke-4 ( $\delta_4(turun)$ ), serta ke-7 ( $\delta_7(turun)$ ) sampai terakhir ( $\delta_{11}(turun)$ ), menjadikan baris ke-4 ( $\psi_4(naik)$ ), ke-5 ( $\psi_5(naik)$ ), serta ke-8 ( $\psi_8(naik)$ ) sampai terakhir di setiap kolom Tabel 4.8 bernilai "2" (turun). Artinya, kondisi kurs rupiah terhadap dolar Amerika Serikat yang paling mungkin terjadi di sebelum pengamatan ke-4, ke-5, serta ke-8 sampai terakhir di setiap kolomnya adalah sama, yaitu "2" yang mengacu terjadinya penurunan. Sementara itu, kondisi

kurs rupiah terhadap dolar Amerika Serikat yang paling mungkin terjadi di sebelum pengamatan ke-2, ke-3, ke-6, dan ke-7 di setiap kolomnya adalah sama, yaitu "1" mengacu terjadinya kenaikan. Dengan adanya variasi ini, tentunya juga berindikasi untuk menjadikan prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat oleh algoritma Viterbi menjadi tidak monoton seperti sebelum menggunakan parameter yang belum dilatih. Berikut hasil prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat di Tabel 4.12 sepanjang data uji (Oktober 2023 - Agustus 2024).

**Tabel 4.12** Tabel Prediksi dan Observasi dengan Bantuan Baum-Welch

Bulan-Tahun	Aktual Kurs	Aktual Inflasi	Prediksi	
			Tanpa Baum-Welch	Dengan Baum-Welch
Oktober-2023	Naik	Naik	<b>Naik</b>	<b>Naik</b>
November-2023	Naik	Turun	Naik	Naik
Desember-2023	Turun	Turun	Naik	<b>Turun</b>
Januari-2024	Turun	Naik	<b>Naik</b>	Turun
Februari-2024	Naik	Naik	<b>Naik</b>	<b>Naik</b>
Maret-2024	Naik	Naik	<b>Naik</b>	<b>Naik</b>
April-2024	Turun	Naik	<b>Naik</b>	Turun
Mei-2024	Turun	Turun	Naik	<b>Turun</b>
Juni-2024	Turun	Naik	<b>Naik</b>	Turun
Juli-2024	Turun	Turun	Naik	<b>Turun</b>
Agustus-2024	Turun	Turun	Naik	<b>Turun</b>

Dari Tabel 4.9 terlihat bahwa model markov tersembunyi yang tidak dilatih memprediksi bahwa kurs rupiah terhadap dolar Amerika Serikat akan mengalami kenaikan di bulan Oktober 2023 sampai Agustus 2024. Tanpa algoritma Baum-Welch, model markov tersembunyi menghasilkan ketepatan prediksi hanya sebanyak 6 dari 11 pengamatan. Berbeda dengan model markov tersembunyi yang terlatih algoritma Baum-Welch, dengan bantuan algoritma Baum-Welch mampu menghasilkan prediksi yang berfluktuasi. Bukan hanya itu, model markov tersembunyi yang terlatih algoritma Baum-Welch memprediksi benar sebanyak 7 dari 11 pengamatan. Seperti yang dihasilkan penelitian sebelumnya [53], algoritma Baum-Welch berhasil meningkatkan ketepatan prediksi urutan *state* tersembunyi, yang mana pada kasus ini adalah kondisi kurs rupiah terhadap dolar Amerika Serikat.

Pada prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat sebelum dilatih dengan algoritma Baum-Welch, didapati kelemahan model markov tersembunyi, yaitu urutan prediksi *state* tersembunyi yang konstan "naik" dari awal sampai akhir pengamatan pada data uji, yang mana pada kasus ini adalah kondisi kurs rupiah terhadap dolar Amerika Serikat. Fenomena ini diakibatkan oleh dominasi probabilitas menetapkan *state* "naik" terhadap berpindahannya ia ke *state* "turun". Selain itu, terjadinya hal ini juga didukung oleh sifat markov yang tidak memiliki memori. Seperti yang diutarakan pada penelitian [54], yang mana transisi *state* hanya bergantung dengan *state* saat ini tanpa adanya pengaruh historis bagaimana *state* tersebut tercapai. Akibatnya, hasil prediksi akan homogen,


dengan *state* "naik" sampai akhir pengamatan. Bukan hanya itu, prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat sebelum dilatih dengan algoritma Baum-Welch, juga didapati kurang mampu mengatasi dependensi temporal jangka panjang. Sebagai mana yang dikemukakan pada penelitian [54], kelemahan dari model markov tersembunyi, yaitu ketidakmampuannya menangkap dependensi temporal jangka panjang, karena sifatnya yang tidak memiliki memori. Berbeda dengan yang terjadi pada hasil prediksi model yang dilatih algoritma Baum-Welch. Hasil prediksi urutan *state* tersembunyi lebih tahan terhadap sifat memori yang dimiliki model, yang mana *state* tersembunyi di sini adalah kondisi kurs rupiah terhadap dolar Amerika Serikat. Hasil prediksi urutan yang mana pada kasus ini adalah kondisi kurs rupiah terhadap dolar Amerika Serikat sepanjang Bulan Oktober 2023 sampai Maret 2024 tidak mengalami hasil prediksi yang monoton naik atau turun, tidak seperti hasil prediksi sebelum pelatihan. Selain itu, dari Bulan Oktober 2023 sampai Maret 2024 model cenderung lebih dapat menangkap dependensi temporal jangka panjang dilihat dari kesesuaian grafiknya di Gambar 4.3. Namun, untuk hasil prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat dari bulan April 2024 sampai Agustus 2024, model yang dilatih algoritma Baum-Welch mulai menunjukkan kelemahannya. Meskipun demikian, dari sini didapati bahwasanya model yang dilatih oleh algoritma Baum-Welch memiliki ketahanan yang lebih terhadap kelemahan sifat tanpa memori dibandingkan dengan model yang tidak dilatih.

Berdasarkan Persamaan 2.27, hasil prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat yang menggunakan model markov tersembunyi menghasilkan probabilitas sebesar  $1.2534 \times 10^{-6}$ , sedangkan jika menggunakan model markov tersembunyi yang dilatih, maka akan menghasilkan probabilitas sebesar 0.0001607193. Hal ini menunjukkan bahwa parameter model markov tersembunyi yang terlatih algoritma Baum-Welch dapat memberikan prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat yang lebih fluktuatif serta juga dapat menghasilkan prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat yang lebih tepat. Lebih dari itu, berdasarkan probabilitas terjadinya urutan kondisi kurs rupiah terhadap dolar Amerika Serikat selaku *state* tersembunyi yang diperoleh menggunakan Persamaan 2.27, maka model markov tersembunyi dengan parameter yang dilatih dengan algoritma baum-welch juga mengungguli probabilitas model dengan parameter sebelum pelatihan. Kedua hasil prediksi ini nantinya dijadikan sebagai pendekatan untuk memprediksi nilai kurs rupiah terhadap dolar Amerika Serikat, kemudian saling dibandingkan ketepatan prediksinya kembali untuk skema perubahan urutan kondisi kurs rupiah terhadap dolar Amerika Serikat ke nilai kontinu.

### 4.3 Prediksi Kurs Rupiah

Untuk kepentingan pendekatan, urutan pola kondisi kenaikan/penurunan kurs rupiah terhadap dolar Amerika Serikat dirubah ke nilai kontinu, dengan menggunakan rerata penurunan/kenaikan. Estimasi nilai kurs dengan menghitung nilai rata-rata penurunan/kenaikan setiap *state* tersembunyi, yang mana pada kasus ini kondisi kurs rupiah terhadap dolar Amerika Serikat, dengan mengadopsi seperti

yang dilakukan pada penelitian [55]. Berdasarkan data latih, diperoleh rerata kenaikan sebesar 215.614 dan penurunan sebesar -202.245. Untuk prediksi di bulan Oktober 2023, diperoleh dari nilai aktual kurs di bulan September 2023 ditambah dengan rerata kenaikan, hal ini karena model yang terlatih dan tidak terlatih memprediksi bahwasanya di bulan Oktober 2023 terjadi kenaikan kurs. Selanjutnya, untuk prediksi kurs di bulan November 2023 sampai Agustus 2024 diperoleh dengan menambah nilai prediksi di bulan sebelumnya, apabila bulan yang ingin diprediksi nilai kursnya kondisi *state* tersembunyinya sedang mengalami kenaikan (jika naik) atau penurunan (jika turun). Perubahan ini bukan hanya berlaku pada model yang belum dilatih, akan tetapi juga diterapkan pada model yang sudah dilatih oleh algoritma Baum-Welch. Berikut adalah hasil prediksi kurs rupiah terhadap dolar Amerika Serikat menggunakan HMM sebelum dilatih dan sesudah dilatih dengan algoritma Baum-Welch.



**Gambar 4.3** Plot Prediksi Berdasarkan Skema Penurunan-Kenaikan

Plot hasil prediksi melalui skema ini menunjukkan bahwa pendekatan melalui model markov tersembunyi terlatih algoritma Baum-Welch mengungguli pendekatan tanpa pelatihan. Model markov tersembunyi yang dilatih algoritma Baum-Welch secara visual menunjukkan pendekatan yang lebih baik. Berikut adalah perbandingan hasil prediksi prediksi kurs rupiah dengan pendekatan model markov tersembunyi yang dilatih algoritma Baum-Welch dan tanpa pelatihan pada Tabel 4.13.

Dari Tabel 4.13 didapatkan selisih nilai aktual dengan prediksi, sehingga dapat dihitung nilai MSE, RMSE, dan MAPE. Sebelum dilatih, pendekatan yang dilakukan HMM menghasilkan MSE, RMSE, dan MAPE sebesar 899485.271, 948.411, dan 5.13%. Di sisi lain, pendekatan yang dilakukan model markov tersembunyi yang sudah dilatih dengan algoritma Baum-Welch menghasilkan

**Tabel 4.13** Tabel Data Kurs dengan Prediksi

Index	Kurs Aktual	Prediksi	Prediksi dengan Pelatihan Baum-Welch
Awal	15430.9700	-	-
1	15819.9300	15646.5843	15646.5843
2	15695.5000	15862.1987	15862.1987
3	15590.9400	16077.8130	15659.4537
4	15688.8700	16293.4273	15456.7087
5	15743.6600	16509.0417	15672.3230
6	15781.1200	16724.6560	15887.9373
7	16180.5000	16940.2703	15685.1923
8	16164.3600	17155.8847	15482.4473
9	16411.0400	17371.4990	15279.7023
10	16342.9600	17587.1133	15076.9573
11	15872.1500	17802.7277	14874.2123

RMSE, MSE, dan MAPE sebesar 429257.466, 655.177, dan 3.03%. Nilai RMSE, MAPE, dan MAPE yang lebih rendah dihasilkan oleh pendekatan model markov tersembunyi terlatih algoritma Baum-Welch. Hal ini menunjukkan bahwasanya model markov tersembunyi yang terlatih algoritma Baum-Welch lebih baik dalam memberikan pendekatan. Namun, terlepas dari itu, antar RMSE dan MSE dengan MAPE terdapat suatu kontradiksi pada setiap pendekatan. Terlihat bahwa nilai MAPE dari kedua jenis pendekatan tergolong kecil, tapi MSE dan RMSE yang dihasilkan mereka tergolong besar. Hal ini disebabkan oleh sifat RMSE serta MSE yang sensitif dengan selisih nilai aktual dan prediksi, sedangkan MAPE hanya relatif terhadap nilai aktual. Pada kasus ini, RMSE dan MSE yang besar menginformasikan bahwa adanya kesalahan yang besar, akan tetapi kesalahan tersebut relatif tidak terlalu menyimpang jauh ditinjau dari data aktual. Berdasarkan Tabel 2.2, nilai MAPE yang dihasilkan oleh kedua model dalam melakukan pendektan mengartikan bahwa kedua model bekerja sangat baik.

## BAB V

### Kesimpulan dan Saran

#### 5.1 Kesimpulan

Dari penelitian yang telah dilakukan, kesimpulan yang dihasilkan sehingga menjawab rumusan masalah untuk mencapai tujuan penelitian adalah sebagai berikut.

1. Model markov tersembunyi berperan dalam memberikan prediksi urutan kondisi kurs rupiah terhadap dolar Amerika Serikat sepanjang observasi. Urutan kondisi kurs rupiah terhadap dolar Amerika Serikat ini akan dijadikan acuan arah prediksi dan menentukan arah perubahan nilai (lebih rendah atau tinggi dari sebelumnya). Model markov tersembunyi memberikan prediksi bahwa dari bulan Oktober 2023 sampai Agustus 2024 kurs rupiah terhadap dolar Amerika Serikat mengalami kenaikan berkelanjutan. Model markov tersembunyi yang dilatih algoritma Baum-Welch juga ikut memberikan prediksi kondisi kurs rupiah terhadap dolar Amerika Serikat, sehingga menghasilkan prediksi naik di bulan Oktober 2023, naik di bulan November 2023, naik di bulan Desember 2023, turun di bulan Desember 2023, turun di bulan Januari 2024, naik di bulan Februari 2024, naik di bulan Maret 2024, turun di bulan April 2024, turun di bulan Mei 2024, turun di bulan Juni 2024, turun di bulan Juli 2024, dan terakhir turun di bulan Agustus 2024. Didapati bahwa adanya penurunan RMSE, MSE, MAPE, serta kenaikan ketepatan prediksi setelah model dilatih dengan algoritma Baum-Welch. RMSE turun dari 948.111 ke 655.177, MSE turun dari 899485.271 ke 429257.466, dan MAPE turun dari 5.12% ke 3.03%. Sepanjang observasi, HMM tanpa pelatihan hanya tepat memprediksi 6 dari 11 *state* tersembunyi aktual, sedangkan HMM yang dilatih dengan algoritma Baum-Welch memprediksi 7 dari 11 kondisi kurs rupiah terhadap dolar Amerika Serikat, serta lebih baik menangkap fluktuasi.
2. Nilai *likelihood* model meningkat dari 0.000053 menjadi 0.001651 setelah dilatih menggunakan algoritma Baum-Welch, yang memperbarui ketiga parameter model. Nilai *likelihood* yang dihasilkan model terlatih mengindikasikan kecocokan relatif model yang lebih tinggi dibandingkan sebelum dilatih. Likelihood yang lebih tinggi ini juga menunjukkan bahwa model yang terlatih lebih mampu merepresentasikan terjadinya urutan *state* observasi yang terjadi.

#### 5.2 Saran

Sebagai bentuk upaya keberlanjutan pembaharuan, disarankan agar memperluas model markov tersembunyi ke bentuk distribusi *state* tersembunyi yang lain. Selain itu, disarankan menggunakan algoritma Baum-Welch yang lebih ketat dalam kriteria pemberhentian, bukan hanya berdasar batas iterasi maksimal. Dari segi skema perubahan *state* tersembunyi ke kontinu, disarankan untuk mencoba

skema lain yang belum digunakan di penelitian ini untuk kepentingan analisis lebih lanjut.



## DAFTAR PUSTAKA

- [1] F. F. R. R. Amelia, “Peramalan kurs rupiah terhadap dolar amerika menggunakan jaringan syaraf tiruan”, *Journal of Mathematics UNP*, 2024.
- [2] A. K. Mufidah, A. S. Anjani, T. Handayani, dan E. P. Astutik, “Systematis literatur review: Analisis faktor perubahan kurs rupiah terhadap valuta asing”, *Student Research Journal*, vol. 1, no. 6, 2023.
- [3] S. Suginam, E. Siska, dan S. Hidayat, “Pengaruh nilai tukar uang, jumlah uang beredar dengan kegiatan export terhadap inflasi pada masa pandemic covid-19”, *Ekonomi, Keuangan, Investasi dan Syariah (EKUITAS)*, vol. 3, no. 2, hlmn. 33–38, Nov. 2021.
- [4] I. Ulya, S. Qothrunnada, dan Sarpini, “Pengaruh teknologi terhadap perkembangan pasar valuta asing”, *Jurnal Akademik Ekonomi dan Manajemen*, vol. 1, no. 4, hlmn. 203–217, Des. 2024.
- [5] R. R. Elhakim, “Prediksi nilai tukar rupiah ke dollar amerika serikat menggunakan metode arima”, *JAMBURA JOURNAL OF PROBABILITY AND STATISTICS*, 2020.
- [6] S. A. Fadilla, dan P. A., “Pengaruh inflasi terhadap pertumbuhan ekonomi indonesia”, *Ekonomika Sharia: Jurnal Pemikiran dan Pengembangan Ekonomi Syariah*, Agt. 2021, [Online]. Available: [www.bps.go.id](http://www.bps.go.id).
- [7] M. H. M. Saefulloh, M. R. Fahlevi, dan S. A. Centauri, “Pengaruh inflasi terhadap pertumbuhan ekonomi: Perspektif indonesia”, *Jurnal Acitya Ardana: Jurnal Keuangan Negara dan Kebijakan Publik*, 2021.
- [8] R. A. Maulana dan L. R. Indrawati, “Pengaruh inflasi, kemiskinan, dan impor terhadap pertumbuhan ekonomi indonesia tahun 1990-2019”, *e-Journal Perdagangan Industri dan Moneter*, 2022.
- [9] C. Musliha, “Pengaruh nilai tukar dan tingkat suku bunga terhadap inflasi di indonesia periode 2000–2022”, *Jurnal Ekuilnomi*, vol. 5, no. 2, hlmn. 322–331, Nov. 2023.
- [10] R. S. Putra, S. I. Jaya, S. P. Bayu, N. Rizki, R. Cahyadi, dan R. A. Yunanda, “Analisis faktor-faktor melemahnya kurs rupiah pada era digital”, *Jurnal Ilmu Ekonomi Manajemen dan Akuntansi MH Thamrin*,
- [11] F. A. et al., “Analisis pengaruh jumlah uang beredar dan kurs rupiah terhadap inflasi di indonesia volume 3 number 2 2023”, *JIEF-Journal of Islamic Economics and Finance*, vol. 3, 2023, [Online]. Available: <http://e-journal.uingusdur.ac.id/index.php/jief/issue/current>.
- [12] G. T. Meilania, A. V. Septiani, E. Erianti, K. A. Notodiputro, dan Y. Angraini, “Pemodelan arima-garch dalam peramalan kurs rupiah terhadap yen dengan masalah keheterogenan ragam”, *Ekonomis: Journal of Economics and Business*, vol. 8, no. 1, hlmn. 165, Mar. 2024.
- [13] N. Wulan dan M. S. Rahman, “Zakat pada masa pandemi covid-19: A systematic literature review”, *AT-TAWASSUTH: Jurnal Ekonomi Islam*, 2021.
- [14] R. M. Putra, G. Ganika, U. Sultan, dan A. Tirtayasa, “Causal relationship between inflation and unemployment in indonesia 1986-2018: A phillips curve analysis”, *Tirtayasa Ekonomika*, 2022.

- [15] E. P. et al., “Dinamika inflasi dan pengangguran di indonesia: Pendekatan model koreksi kesalahan vektor (vecm)”, *Jurnal Akuntansi dan Manajemen Berkontemplasi dan Bernalar (SINAR)*, 2023.
- [16] S. M. et al., “Dinamika kebijakan moneter dan diplomasi ekonomi dalam menjaga stabilitas nilai tukar”, *Moneter: Jurnal Ekonomi dan Keuangan*, Des. 2024.
- [17] Z. A. H. M. dan Syamsul Hadi, “Nilai tukar dan kedaulatan rupiah”, *SOSIO-E-KONS*, 2016.
- [18] H. Hasyim, “Analisis faktor-faktor yang mempengaruhi perubahan nilai tukar di indonesia tahun 2006-2018”, *Jurnal Al-Iqtishad*, 2018.
- [19] R. Saiyed, “Pengendalian inflasi, moneter dan fiskal dalam perspektif ekonomi makro islam”, *Jurnal Ilmiah Bongaya(JIB)*, 2021.
- [20] G. P. B. Are dan S. H. Sitorus, “Prediksi nilai tukar mata uang rupiah terhadap dolar amerika menggunakan metode hidden markov model”, *Coding : Jurnal Komputer dan Aplikasi*, 2020.
- [21] Mahmudi dan Ardi, “Prediksi pergerakan nilai tukar rupiah terhadap dolar amerika serikat menggunakan hidden markov model (hmm)”, *Jurnal “LOG!K@”*, 2016.
- [22] S. Abdullah dkk., “Generalisasi algoritma thinning process pada proses poisson majemuk dengan komponen proses poisson nonhomogen dan distribusi gamma”, *MUST: Journal of Mathematics Education, Science and Technology*, vol. 5, no. 2, hlmn. 221, Des. 2020.
- [23] F. Jeka, M. S. Jailani, dan U. I. N. S. T. S. Jambi, “Kajian literatur dalam menyusun referensi kunci, state of the art, dan keterbaharuan penelitian (novelty)”, *Jurnal Pendidikan Tambusai*, Des. 2023.
- [24] M. T. Jatipaningrum, K. Suryowati, dan L. M. M. E. Un, “Prediksi kurs rupiah terhadap dolar dengan fts-markov chain dan hidden markov model”, *Jurnal Derivat: Jurnal Matematika dan Pendidikan Matematika*, 2019.
- [25] P. N. Halisania, M. I. Jafar, D. Wahyuningsih, dan N. Azizah, “Pengaruh inflasi, kurs, pdb, jumlah uang beredar, dan bi rate terhadap indeks saham syariah indonesia”, *Advances In Social Humanities Research*, 2024.
- [26] D. Efriyenty, “Pengaruh inflasi dan kurs terhadap harga saham di industri dasar dan kimia”, *Going Concern : Jurnal Riset Akuntansi*, 2020, <http://www.bi.go.id>.
- [27] Y. W. T. F. Yanti, D. Soebagiyo, dkk., “Analisis pengaruh jub, suku bunga, dan nilai tukar terhadap inflasi di indonesia tahun 2005-2021”, *Jurnal Ekonomi Pembangunan STIE Muhammadiyah Palopo*, 2022.
- [28] J. Sungkono dan K. Nugrahaningsih, “Pembelajaran teori probabilitas menggunakan r”, *Absis: Mathematics Education Journal*, vol. 2, no. 1, hlmn. 1, Mar. 2021.
- [29] W. R, M. R, M. S, dan Y. K, *Probability and Statistics for Engineers Scientists (9th Edition)*. Prentice Hall, 2011.
- [30] T. Darmanto, “Penerapan bayesian probability pada sistem pakar pendiagnosis penyakit”, *Jurnal InTekSis*, 2017.

- [31] J. P. Coelho, T. M. Pinho, dan J. Boaventura-Cunha, *Hidden Markov Models: Theory and Implementation Using MATLAB*. CRC Press, Taylor & Francis Group, 2019.
- [32] Y. A. R. Langi, “Penentuan klasifikasi state pada rantai markov dengan menggunakan nilai eigen dari matriks peluang transisi”, *JURNAL ILMIAH SAINS*, 2011.
- [33] H. M. Taylor dan S. Karlin, *An Introduction to Stochastic Modeling, Third Edition*. Academic Press, 1998.
- [34] S. W. Mamonto, Y. A. R. Langi, dan A. J. Rindengan, “Penerapan hidden markov model pada harga saham”, *d’CartesiaN : Jurnal Matematika dan Aplikasi*, 2016.
- [35] P. Dymarski, *Hidden Markov Models, Theory and Applications*. INTECH Open Access Publisher, 2011.
- [36] T. S. Himawan, T. Indriyani, dan W. M. Rahmawati, “Implementasi hidden markov model untuk memprediksi pergerakan harga forex (foreign exchange)”, *d’CartesiaN : Jurnal Matematika dan Aplikasi*, 2016.
- [37] J. Bilmes, “What hmms can do”, 2002.
- [38] C. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [39] Z. Cvetkovski, *Inequalities: Theorems, Techniques and Selected Problems*. Springer, 2012.
- [40] T. M. Manik, P. Gultom, dan E. Nababan, “Analisis karakteristik fungsi lagrange dalam menyelesaikan permasalahan optimasi berkendala”, *Talenta Conference Series: Science and Technology (ST)*, vol. 1, no. 1, hlmn. 037–043, Okt. 2018.
- [41] J. Nocedal dan S. J. Wright, *Numerical Optimization*. Springer, Juli 2006.
- [42] R. Juanda dan I. Yadi, “Penerapan rule based dengan algoritma viterbi untuk deteksi kesalahan huruf kapital pada karya ilmiah”, *Journal of Computer and Information Systems Ampera*, 2020.
- [43] M. K. Selian, “Penerapan algoritma viterbi dalam memprediksi jumlah penumpang (studi kasus: Pt. als)”, *Jurnal Pelita Informatika*, vol. 8, no. 3, 2020.
- [44] E. H. T. L. Purnama dan N. A. M. Huda, “Aplikasi algoritma viterbi dalam hidden markov model untuk menganalisis trend pasar saham di bursa efek (studi kasus di pt. bank central asia, tbk.)”, *JEM*, 2023, <https://ejournal.upi.edu/index.php/JEM>.
- [45] D. Jurafsky dan J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. Prentice Hall, 2000.
- [46] D. M. Efendi, D. Sartika, A. I. Waspah, dan A. Afandi, “Expectation maximization algorithm memprediksi penjualan susu murni pada pt. sewu primatama indonesia lampung tengah”, *Jurnal Teknik Informatika Musirawas*, 2022.
- [47] D. Zhao, H. Wang, dan S. Geng, “Compound attack prediction method based on improved algorithm of hidden markov model”, *Journal of Web Engineering*, vol. 19, hlmn. 1213–1238, 2020.

- [48] D. Chicco, M. J. Warrens, dan G. Jurman, “The coefficient of determination r-squared is more informative than smape, mae, mape, mse and rmse in regression analysis evaluation”, *PeerJ Comput Sci*, vol. 7, hlmn. 1–24, 2021.
- [49] U. Azmi, Z. N. Hadi, dan S. Soraya, “Ardl method: Forecasting data curah hujan harian ntb”, *Jurnal Varian*, vol. 3, no. 2, hlmn. 73–82, Mei 2020.
- [50] M. A. Maricar, “Analisa perbandingan nilai akurasi moving average dan exponential smoothing untuk sistem peramalan pendapatan pada perusahaan xyz”, *JURNAL SISTEM DAN INFORMATIKA*, 2019.
- [51] M. J. W. Fanny Yang Sivaraman Balakrishnan, “Statistical and computational guarantees for the baum-welch algorithm”, *Journal of Machine Learning Research*, 2017.
- [52] P. D. Sovan Mitra, “Journal of computational and applied mathematics”, *Journal of Computational and Applied Mathematics*, 2010.
- [53] D. K. A.M.Pushpalatha, “Using baum-welch algorithm for sharing finegrained knowledge in mutual environments”, *IJSTE - International Journal of Science Technology Engineering*, 2016.
- [54] G. T. Haywood dan S. N. Bhatti, “Defence against sidechannel attacks for encrypted network communication using multiple paths”, *Cryptography*, vol. 8, no. 2, hlmn. 22, 2024. sumber: <https://doi.org/10.3390/cryptography8020022>.
- [55] Y. A. PRADANA, “Analisis data cuaca untuk estimasi produksi padi dengan menggunakan metode hidden markov model”, Master’s thesis, INSTITUT TEKNOLOGI SEPULUH NOPEMBER, Surabaya, Indonesia, 2018.

# LAMPIRAN

## LAMPIRAN A

### Perhitungan Manual

#### A.1 Parameter Awal

$$A = \begin{pmatrix} 0.5862069 & 0.4137931 \\ 0.5 & 0.5 \end{pmatrix}$$
$$B = \begin{pmatrix} 0.5 & 0.5 \\ 0.4615385 & 0.5384615 \end{pmatrix}$$
$$\pi = (0.5357143 \quad 0.4642857)$$

#### A.2 Urutan Observasi

Urutan observasi: “1,1,2,2,1,1,2,2,2,2,2” dengan:

- “1” = Naik
- “2” = Turun

#### A.3 Algoritma Viterbi

##### A.3.1 Perhitungan $\delta_t(i)$

$$\begin{aligned} \delta_1(1) &= \pi_1 \cdot b_1(O_1) = 0.535 \times 0.5 = 0.2675 \\ \delta_1(2) &= \pi_2 \cdot b_2(O_1) = 0.464 \times 0.461 = 0.2142 \\ \delta_2(1) &= \max(\delta_1(1) \cdot a_{11}, \delta_1(2) \cdot a_{21}) \cdot b_1(O_2) \\ &= \max(0.2675 \times 0.586, 0.2139 \times 0.5) \times 0.5 \\ &= 0.1568 \times 0.5 = 0.0785 \\ \delta_2(2) &= \max(\delta_1(1) \cdot a_{12}, \delta_1(2) \cdot a_{22}) \cdot b_2(O_2) \\ &= \max(0.2675 \times 0.413, 0.2139 \times 0.5) \times 0.461 \\ &= 0.1105 \times 0.461 = 0.0511 \end{aligned}$$

Dengan melanjutkan perhitungan  $\delta_t$  sampai  $t=11$  untuk setiap *hidden* state maka diperoleh

### A.3.2 Tabel $\delta_t(i)$

$t$	$\delta_{\text{naik}}$	$\delta_{\text{turun}}$
1	0.267857	0.214286
2	0.078510	0.051156
3	0.023011	0.017493
4	0.006745	0.005127
5	0.001977	0.001288
6	0.000579	0.000378
7	0.000170	0.000129
8	0.000050	0.000038
9	0.000015	0.000011
10	0.000004	0.000003
11	0.000001	0.0000009

### A.3.3 Perhitungan $\psi_t(i)$

$$\begin{aligned}
\psi_2(\text{naik}) &= \arg \max[\delta_1(\text{naik}) \cdot a_{\text{naik,naik}}, \delta_1(\text{turun}) \cdot a_{\text{turun,naik}}] \\
&= \arg \max[0.267857 \times 0.586, 0.214286 \times 0.5] \\
&= \arg \max[0.1570, 0.1071] = 1 \\
\psi_2(\text{turun}) &= \arg \max[\delta_1(\text{naik}) \cdot a_{\text{naik,turun}}, \delta_1(\text{turun}) \cdot a_{\text{turun,turun}}] \\
&= \arg \max[0.267857 \times 0.413, 0.214286 \times 0.5] \\
&= \arg \max[0.1106, 0.1071] = 1
\end{aligned}$$

Dengan melanjutkan perhitungan  $\psi_t$  sampai  $t=11$  untuk setiap *hidden* state maka diperoleh

### A.3.4 Tabel $\psi_t(i)$

$t$	$\psi_{\text{naik}}$	$\psi_{\text{turun}}$
1	-	-
2	1	1
3	1	1
4	1	1
5	1	1
6	1	1
7	1	1
8	1	1
9	1	1
10	1	1
11	1	1

#### A.4 Perhitungan $\alpha$ dan $\beta$

##### A.4.1 Perhitungan $\alpha_t(i)$

$$\alpha_1(\text{naik}) = \pi_{\text{naik}} \cdot b_{\text{naik}}(O_1) = 0.5357143 \times 0.5 = 0.26785715$$

$$\alpha_1(\text{turun}) = \pi_{\text{turun}} \cdot b_{\text{turun}}(O_1) = 0.4642857 \times 0.4615385 = 0.21428572$$

$$\begin{aligned}\alpha_2(1) &= (\alpha_1(1) \cdot a_{11} + \alpha_1(2) \cdot a_{21}) \cdot b_1(O_2) \\ &= (0.26785715 \times 0.5862069 + 0.2142857255 \times 0.5) \times 0.5 \\ &= 0.1320812862\end{aligned}$$

$$\begin{aligned}\alpha_2(2) &= (\alpha_1(1) \cdot a_{12} + \alpha_1(2) \cdot a_{22}) \cdot b_2(O_2) \\ &= (0.26785715 \times 0.4137931 + 0.2142857255 \times 0.5) \times 0.4615385 \\ &= 0.1006063022\end{aligned}$$

Dengan melanjutkan perhitungan  $\alpha_t$  sampai  $t=11$  untuk setiap *hidden state* maka diperoleh

##### A.4.2 Tabel $\alpha_t(i)$

$t$	$\alpha_t(\text{naik})$	$\alpha_t(\text{turun})$
1	0.2678571500	0.2142857255
2	0.1320812862	0.1006063022
3	0.0638650562	0.0565155599
4	0.0328479583	0.0294456053
5	0.0169892512	0.0130684909
6	0.0082467309	0.0062604376
7	0.0039822547	0.0035229701
8	0.0020479551	0.0018357846
9	0.0010592089	0.0009505579
10	0.0005480973	0.0004919235
11	0.0002836301	0.0002545634

##### A.4.3 Likelihood Model

$$P(O|\theta) = \alpha_{11}(\text{naik}) + \alpha_{11}(\text{turun}) = 0.0002836301 + 0.0002545634 = 0.0005381935$$

#### A.5 Perhitungan $\beta$

##### A.5.1 Inisialisasi $\beta_{11}(i)$

$$\beta_{11}(\text{naik}) = 1 \quad \beta_{11}(\text{turun}) = 1$$



### A.5.2 Perhitungan $\beta_{10}(i)$

$$\begin{aligned}
\beta_{10}(\text{naik}) &= a_{11}b_1(O_{11})\beta_{11}(1) + a_{12}b_2(O_{11})\beta_{11}(2) \\
&= (0.5862069 \times 0.5 \times 1) + (0.4137931 \times 0.5384615 \times 1) \\
&= 0.29310345 + 0.22258264 = 0.515915103 \\
\beta_{10}(\text{turun}) &= a_{21}b_1(O_{11})\beta_{11}(1) + a_{22}b_2(O_{11})\beta_{11}(2) \\
&= (0.5 \times 0.5 \times 1) + (0.5 \times 0.5384615 \times 1) \\
&= 0.25 + 0.26923075 = 0.51923075
\end{aligned}$$

Dengan melanjutkan perhitungan  $\beta_t$  sampai  $t=1$  untuk setiap *hidden* state maka diperoleh

### A.5.3 Tabel $\beta_t(i)$

$t$	$\beta_t(\text{naik})$	$\beta_t(\text{turun})$
1	0.001119369	0.001112359
2	0.002306035	0.002322015
3	0.004458664	0.004484440
4	0.008669883	0.008605886
5	0.017954134	0.017841859
6	0.036986107	0.037246437
7	0.071473043	0.071976087
8	0.138116867	0.139088385
9	0.266907159	0.268771660
10	0.515915103	0.519230750
11	1.000000000	1.000000000

## A.6 Perhitungan $\xi$ dan $\gamma$

### A.6.1 Rumus $\xi_t(i, j)$

$$\xi_t(i, j) = \frac{\alpha_t(i) \cdot a_{ij} \cdot b_j(O_{t+1}) \cdot \beta_{t+1}(j)}{P(O|\theta)}$$

### A.6.2 Contoh Perhitungan $\xi_1(i, j)$

$$\begin{aligned}
\xi_1(\text{naik}, \text{naik}) &= 0.3364 \\
\xi_1(\text{naik}, \text{turun}) &= 0.2207 \\
\xi_1(\text{turun}, \text{naik}) &= 0.2295 \\
\xi_1(\text{turun}, \text{turun}) &= 0.2134
\end{aligned}$$

**A.6.3 Tabel  $\xi_t(i, j)$** 

$t$	$\xi_t(\text{naik, naik})$	$\xi_t(\text{naik, turun})$	$\xi_t(\text{turun, naik})$	$\xi_t(\text{turun, turun})$
1	0.3364	0.2207	0.2295	0.2134
2	0.3207	0.2452	0.2084	0.2257
3	0.3015	0.2275	0.2276	0.2433
4	0.3212	0.2080	0.2456	0.2253
5	0.3422	0.2245	0.2245	0.2087
6	0.3210	0.2457	0.2078	0.2254
7	0.2995	0.2293	0.2260	0.2451
8	0.2977	0.2279	0.2276	0.2468
9	0.2976	0.2277	0.2278	0.2469
10	0.2985	0.2269	0.2285	0.2461

**A.6.4 Rumus  $\gamma_t(i)$** 

$$\gamma_t(i) = \frac{\alpha_t(i) \cdot \beta_t(i)}{P(O|\theta)}$$

**A.6.5 Tabel  $\gamma_t(i)$** 

$t$	$\gamma_t(\text{naik})$	$\gamma_t(\text{turun})$
1	0.5571	0.4429
2	0.5659	0.4341
3	0.5291	0.4709
4	0.5292	0.4708
5	0.5668	0.4332
6	0.5667	0.4333
7	0.5289	0.4711
8	0.5256	0.4744
9	0.5253	0.4747
10	0.5254	0.4746
11	0.5270	0.4729

## A.7 Pembaruan Parameter

### A.7.1 Matriks Transisi $A^*$

$$\begin{aligned}A_{\text{naik,naik}}^* &= \frac{\sum_{t=1}^{10} \xi_t(\text{naik,naik})}{\sum_{t=1}^{10} \gamma_t(\text{naik})} = 0.5787 \\A_{\text{turun,naik}}^* &= \frac{\sum_{t=1}^{10} \xi_t(\text{turun,naik})}{\sum_{t=1}^{10} \gamma_t(\text{turun})} = 0.4920 \\A_{\text{naik,turun}}^* &= \frac{\sum_{t=1}^{10} \xi_t(\text{naik,turun})}{\sum_{t=1}^{10} \gamma_t(\text{naik})} = 0.4213 \\A_{\text{turun,turun}}^* &= \frac{\sum_{t=1}^{10} \xi_t(\text{turun,turun})}{\sum_{t=1}^{10} \gamma_t(\text{turun})} = 0.5080\end{aligned}$$

### A.7.2 Matriks Emisi $B^*$

$$\begin{aligned}B_{\text{naik,naik}}^* &= \frac{\sum_{t=1}^{11} \gamma_t(\text{naik})I(O_t = \text{naik})}{\sum_{t=1}^{11} \gamma_t(\text{naik})} = 0.3794 \\B_{\text{naik,turun}}^* &= \frac{\sum_{t=1}^{11} \gamma_t(\text{naik})I(O_t = \text{turun})}{\sum_{t=1}^{11} \gamma_t(\text{naik})} = 0.6206 \\B_{\text{turun,turun}}^* &= \frac{\sum_{t=1}^{11} \gamma_t(\text{turun})I(O_t = \text{turun})}{\sum_{t=1}^{11} \gamma_t(\text{turun})} = 0.6550 \\B_{\text{turun,naik}}^* &= \frac{\sum_{t=1}^{11} \gamma_t(\text{turun})I(O_t = \text{naik})}{\sum_{t=1}^{11} \gamma_t(\text{turun})} = 0.3450\end{aligned}$$

### A.7.3 Vektor Probabilitas Awal $\pi^*$

$$\pi^* = (\gamma_1(\text{naik}) \quad \gamma_1(\text{turun})) = (0.5571 \quad 0.4429)$$

## A.8 Parameter Hasil Pelatihan

Setelah iterasi pelatihan diperoleh parameter terbaru:

$$A = \begin{pmatrix} 0.5495 & 0.4505 \\ 0.3082 & 0.6918 \end{pmatrix}, \quad B = \begin{pmatrix} 0.6160 & 0.3840 \\ 0.1304 & 0.8696 \end{pmatrix}, \quad \pi = (0.9918 \quad 0.0082)$$

## A.9 Prediksi dan Evaluasi

### A.9.1 Urutan State Tersembunyi

Prediksi dengan parameter terbaru:

[Naik, Naik, Turun, Turun, Naik, Naik, Turun, Turun, Turun, Turun, Turun]

### A.9.2 Konversi ke Nilai Kontinu

- Jika state = Naik: Nilai = Nilai sebelumnya – 215.614
- Jika state = Turun: Nilai = Nilai sebelumnya + 202.245

### A.9.3 Evaluasi Prediksi

Metrik	Parameter Awal	Parameter Terlatih
RMSE	948.111	655.177
MSE	899485.271	429257.466
MAPE	5.12%	3.03%